

Introducción

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

- 1 ¿Qué Es la Ciencia de Datos?
- 2 ¿Por Qué Nos Importa?
- 3 Parámetros Objetivo: ¿Qué Estamos Buscando?
- 4 Regresión: Nuestro Primer Estimador
- 5 Más Allá de la Regresión
- 6 Sobre el Curso
- 7 Repaso

¿Qué Es la Ciencia de Datos?

Ciencia de Datos es el proceso de usar datos para **entender el mundo, predecir comportamientos y tomar decisiones.**

Analytics And Data Science

Data Scientist: The Sexiest Job of the 21st Century

Meet the people who can coax treasure out of messy, unstructured data. by Thomas H. Davenport and DJ Patil

Fuente: Davenport y Patil (2012), *Harvard Business Review*.

¿Qué Es la Ciencia de Datos?

¿Qué Implica?

- ▶ Recolección y análisis de *big data*
- ▶ Herramientas de múltiples disciplinas:
 - ▶ **Aprendizaje de Máquinas** (*machine learning*) para predicción
 - ▶ Estadística y **Econometría** para inferencia y causalidad
 - ▶ Visualización para comunicar hallazgos
 - ▶ Programación y bases de datos para manipulación y escalabilidad

¿Qué Es Big Data?

- ▶ Big n, muchos datos, es solo parte de la historia
- ▶ Big también es big p, muchas covariables, a veces $n \ll p$
- ▶ Vamos a entender Big también como datos que no surgen de fuentes tradicionales.
- ▶ Las 4 V:
 - ▶ **Volumen:** grandes cantidades de datos
 - ▶ **Variedad:** múltiples tipos y fuentes
 - ▶ **Velocidad:** generación continua
 - ▶ **Veracidad:** calidad y ruido

¿Qué Es el Aprendizaje de Máquinas?

El Aprendizaje de Máquinas Trata sobre Predicción



- ▶ El aprendizaje de máquinas es una rama de la informática y la estadística, dedicada a desarrollar algoritmos para predecir resultados Y a partir de variables observables X .
- ▶ Nos interesa $\hat{Y}$
- ▶ Esto se deja como un problema empírico que “la máquina” puede “aprender”.
- ▶ En general, esto significa que abstraemos del modelo subyacente, el enfoque es pragmático.

¿Qué Es la Econometría?

La Econometría Trata sobre Parámetros

- ▶ La econometría busca medir relaciones económicas con datos.
- ▶ Lo que nos interesa no es $\hat{Y}$, sino un **parámetro** β con contenido económico: una elasticidad, el retorno a la educación, el efecto de un programa.
- ▶ En econometría los problemas centrales son:
 - ▶ **Identificación:** ¿bajo qué supuestos $\hat{\beta}$ recupera el parámetro que nos importa? (exogeneidad, VI, DiD, RDD, paneles)
 - ▶ **Inferencia:** ¿cuánta incertidumbre tiene esa medición? (errores estándar, tests, intervalos)

Aprendizaje de Máquinas y Econometría



Aprendizaje de Máquinas y Econometría

Dos Culturas, Dos Preguntas

	Aprendizaje de Máquinas	Econometría
Pregunta	¿Cuál es el valor de Y dado X ?	¿Cuál es el efecto de X sobre Y ?
Objetivo	$\hat{Y}$, la función f^*	β , el ATT
Éxito	Error fuera de muestra	Insensibilidad, consistencia, cobertura
El modelo	Lo elige el algoritmo	Lo dictan la teoría y la identificación
El enemigo	Sobreajuste	Sesgo (variable omitida, endogeneidad)

Un modelo puede tener un R^2 altísimo y un $\hat{\beta}$ inservible; y un $\hat{\beta}$ bien identificado puede predecir pésimo.

¿Rivales?

- ▶ Muchas decisiones son de predicción pura: a quién auditar, qué paciente priorizar, qué estudiante está en riesgo de desertar.
- ▶ ¿Llevo paraguas o hago la danza de la lluvia?
 - ▶ **Paraguas:** solo necesito *predecir* si va a llover
 - ▶ **Danza de la lluvia:** necesito el *efecto causal* del baile sobre la lluvia
- ▶ Y al revés: la econometría moderna usa aprendizaje de máquinas *como insumo* para estimar efectos causales (Lasso para elegir controles, bosques causales para heterogeneidad)

Tres Preguntas Que Nos Interesan

- ▶ ¿Podemos predecir resultados?
Dadas las características, ¿qué pasa después?
- ▶ ¿Cuál es el efecto causal de una intervención?
Si cambiamos X , ¿cuánto cambia Y ?
- ▶ ¿Qué características importan más?
¿Qué explica la variación en los resultados?

Agenda

- 1 ¿Qué Es la Ciencia de Datos?
- 2 ¿Por Qué Nos Importa?**
- 3 Parámetros Objetivo: ¿Qué Estamos Buscando?
- 4 Regresión: Nuestro Primer Estimador
- 5 Más Allá de la Regresión
- 6 Sobre el Curso
- 7 Repaso

Predicción: Google Flu Trends (2009)

Un problema de predicción de salud pública en tiempo real.

- ▶ El CDC mide la gripe con visitas al médico, reportadas con un **rezago de 10 días**
- ▶ Google: las búsquedas son en tiempo real ¿podemos usarlas para predecir la actividad de la gripe?
- ▶ Ginsberg et al. probaron **450 millones** de modelos candidatos y eligieron el de mejor ajuste
- ▶ Resultado: estimaciones con **1 día de rezago**, publicadas en *Nature*¹

¹Ginsberg et al. (2009), *Nature* 457:1012–1014.

Google Flu Trends: La Promesa





Figure 3 | ILI percentages estimated by our model (black) and provided by the CDC (red) in the mid-Atlantic region, showing data available at four points in the 2007-2008 influenza season. During week 5 we detected a sharply increasing ILI percentage in the mid-Atlantic region; similarly, on 3 March our model indicated that the peak ILI percentage had been reached during week 8, with sharp declines in weeks 9 and 10. Both results were later confirmed by CDC ILI data.

Fuente: Ginsberg et al. (2009), *Nature* 457:1012–1014.

Google Flu Trends: ... y la Caída

- ▶ Para 2013, GFT estimaba **más del doble** de la prevalencia real de gripe reportada por el CDC
- ▶ Lazer et al. (*Science*, 2014): “soberbia del *big data*” + dinámica del algoritmo
- ▶ Google archivó el proyecto discretamente


Lección: un modelo puede ajustar el pasado perfectamente y aun así fallar mañana.



Fuente: Lazer et al. (2014), *Science* 343:1203–1205.

Predicción: El Netflix Prize (\$1 millón)

- ▶ 2006: Netflix ofreció **\$1M** a quien mejorara su predictor de calificaciones de películas en 10%
- ▶ Idea ganadora: **factorización de matrices**: usuarios y películas como vectores de factores latentes
- ▶ Koren, Bell & Volinsky (*IEEE Computer*, 2009)



Inferencia Causal en Política Pública: Familias en Acción

Transferencia condicionada de Colombia (desde 2001).

- ▶ Subsidio de **US\$8–16/mes por hijo** si la asistencia es $\geq 80\%$
- ▶ 691 municipios elegibles; comparación de tratados vs. controles
- ▶ Attanasio et al. (IFS, 2005)

Table 1. Impact of FA on percentage of children who attend school

	Without FA	With FA	Impact
<i>Rural</i>			
Aged 8–11	93.0%	93.1%	0.1
Aged 12–17	46.2%	56.3%	10.1*
<i>Urban</i>			
Aged 8–11	95.2%	96.6%	1.4
Aged 12–17	68.5%	73.7%	5.2*

* Statistically significantly different from zero at the 95% confidence level.

Fuente: Attanasio et al. (2005), IFS Briefing Note BN54.

Pregunta causal: ¿cuánto aumentó la asistencia de los niños *a causa del* programa?

Inferencia Causal en la Empresa: Booking.com

- ▶ Booking.com corre **~25.000 pruebas A/B al año**
- ▶ Cualquiera puede lanzar un experimento — sin necesitar autorización de un gerente
- ▶ ~9 de cada 10 ideas *fallan* en la prueba, pero con riesgo cero para el sitio en producción



Las empresas que experimentan sistemáticamente superan al mercado.

Agenda

- 1 ¿Qué Es la Ciencia de Datos?
- 2 ¿Por Qué Nos Importa?
- 3 **Parámetros Objetivo: ¿Qué Estamos Buscando?**
- 4 Regresión: Nuestro Primer Estimador
- 5 Más Allá de la Regresión
- 6 Sobre el Curso
- 7 Repaso

¿Qué Es un Parámetro Objetivo?

Un **estimando** es la cantidad verdadera que queremos conocer.

- ▶ **Objetivo:** Lo que nos importa (el parámetro verdadero)
- ▶ **Estimador:** Nuestro método con los datos para estimarlo
- ▶ **Estimación:** El resultado obtenido con nuestros datos

Ejemplo: Estatura promedio de los estudiantes de Uniandes.

- ▶ **Objetivo:** Media verdadera μ
- ▶ **Estimador:** Media muestral $\bar{X}$
- ▶ **Estimación:** Un número calculado con nuestros datos

Importante: Un mismo parámetro objetivo puede tener varios estimadores. La elección depende de los datos, el diseño muestral y los supuestos que estemos dispuestos a hacer.

Parámetro Objetivo 1: La Función de Regresión

La **esperanza condicional**:

$$f^*(x) = \mathbb{E}[Y \mid X = x]$$

- Valor promedio de Y cuando $X = x$
- Es la solución de minimizar el error esperado de predicción bajo **pérdida cuadrática**:


$$f^*(x) = \arg \min_g \mathbb{E}[(Y - g(X))^2 \mid X = x]$$

Por eso f^* es la mejor “adivinanza” para Y si conocemos X : ninguna otra función $g(X)$ logra un error cuadrático esperado menor.

Nos interesa f^* porque queremos **predecir resultados**.

Parámetro Objetivo 1: La Función de Regresión

Visualizando f^*



Parámetro Objetivo 2: Efectos de Tratamiento

Imaginemos que cada persona tiene dos resultados potenciales:

- ▶ $Y(1)$ = resultado si es tratada
- ▶ $Y(0)$ = resultado si no es tratada

El efecto de tratamiento para esa persona es:

$$Y(1) - Y(0)$$

Ejemplo (Familias en Acción): efecto del subsidio condicionado sobre la asistencia escolar.

- ▶ $Y(1)$ = asistencia escolar del niño CON subsidio
- ▶ $Y(0)$ = asistencia escolar del niño SIN subsidio
- ▶ Efecto = cuánto aumentó la asistencia por el programa

Efecto Promedio del Tratamiento en los Tratados (ATT)

Nos interesa el efecto promedio **para las personas que fueron tratadas**:


$$ATT = \mathbb{E}[Y(1) - Y(0) \mid T = 1]$$

- ▶ Siguiendo con Familias en Acción: para los niños que recibieron el subsidio, ¿cuánto más alta es su asistencia escolar gracias a él?
- ▶ Es una cantidad **causal** (responde preguntas del tipo “¿qué habría pasado si...?”)
- ▶ Es distinta de la correlación porque pregunta: ¿qué pasaría si cambiáramos el tratamiento?

Resultados Potenciales: Dos Mundos


El Mundo de los Resultados Potenciales

Efecto



Ambos existen para cada persona.
Solo observamos uno.

Lo Que Observamos



Nunca vemos ambos.
Falta el contrafactual.

Agenda

- 1 ¿Qué Es la Ciencia de Datos?
- 2 ¿Por Qué Nos Importa?
- 3 Parámetros Objetivo: ¿Qué Estamos Buscando?
- 4 Regresión: Nuestro Primer Estimador**
- 5 Más Allá de la Regresión
- 6 Sobre el Curso
- 7 Repaso

¿Qué Es un Estimador?

Un **estimador** es un método con datos para estimar un objetivo.

La **regresión** es un estimador de f^* (y de efectos de tratamiento).

- ▶ Tenemos dos objetivos: f^* y el ATT
- ▶ La regresión es UNA forma de estimarlos
- ▶ Árboles, bosques y otros métodos también estiman los mismos objetivos
- ▶ Misma meta, camino distinto

Regresión Lineal

La regresión supone que f^* es lineal en los parámetros:

$$f^*(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$


¿Por qué lineal?

- ▶ Simple: fácil de interpretar (pendiente = cambio por unidad)
- ▶ Suele funcionar: las relaciones suaves son aproximadamente lineales
- ▶ Computable: tenemos algoritmos rápidos

Regresión Lineal

Una Nota Histórica: Los MCO Nacieron para Predecir

- ▶ **1801:** el astrónomo italiano Piazzi descubre el asteroide **Ceres**, lo observa durante 41 días y luego lo pierde detrás del Sol.
- ▶ El reto: *predecir* dónde reaparecerá Ceres.
- ▶ Un Carl Friedrich Gauss de 24 años desarrolla mínimos cuadrados, predice la órbita y acierta.
 - ▶ Publica el método en *Theoria Motus* (1809).
- ▶ Los MCO se inventaron para *predecir* la posición de un cuerpo celeste.
- ▶ La interpretación causal de la regresión llegó mucho después.



*Ceres reaparece donde
Gauss dijo que lo haría.*

Mínimos Cuadrados Ordinarios (MCO)

En la **población**, el objetivo minimiza el error cuadrático esperado:

$$\beta = \arg \min_b \mathbb{E}[(Y - X^\top b)^2]$$

Esa esperanza no la conocemos. La reemplazamos por su análogo en la **muestra**:

$$\hat{\beta} = \arg \min_b \sum_{i=1}^n (y_i - x_i^\top b)^2 \quad \implies \quad \hat{\beta} = (X^\top X)^{-1} X^\top Y$$

- ▶ β es el objetivo; $\hat{\beta}$ es la estimación que sale de nuestros datos
- ▶ $\hat{\beta}_j$ = pendiente estimada de la variable j : cuánto cambia Y por cada unidad de cambio en X_j

¿Cuándo Funciona Bien la Regresión Lineal?

Funciona:

- ▶ El verdadero f^* es efectivamente lineal
- ▶ Las relaciones son suaves y aditivas
- ▶ No hay interacciones fuertes ni umbrales

Falla:

- ▶ f^* es altamente no lineal (árboles, saltos, curvas)
- ▶ Las características interactúan fuertemente
- ▶ Datos de alta dimensión (p grande relativo a n)

Usando Regresión para Estimar el ATT

En casos simples, un coeficiente de regresión estima el efecto de tratamiento. Siguiendo con Familias en Acción:

$$\text{Asistencia} = \beta_0 + \beta_1 \cdot \text{Subsidio} + \epsilon$$

Entonces el objetivo es $\beta_1 = \text{ATT}$, y $\hat{\beta}_1$ es la estimación que obtenemos de los datos.

¡Pero cuidado!


- Solo funciona si el subsidio no está relacionado con todo lo demás que afecta la asistencia:

$$\mathbb{E}[\epsilon \mid \text{Subsidio}] = 0$$

Agenda

- 1 ¿Qué Es la Ciencia de Datos?
- 2 ¿Por Qué Nos Importa?
- 3 Parámetros Objetivo: ¿Qué Estamos Buscando?
- 4 Regresión: Nuestro Primer Estimador
- 5 Más Allá de la Regresión**
- 6 Sobre el Curso
- 7 Repaso

La Regresión No Es el Único Camino



- ▶ Métodos distintos estiman los mismos objetivos
- ▶ Árboles y bosques: estimadores alternativos de f^*
- ▶ Bosques causales: estimadores directos de efectos de tratamiento

Agenda

- 1 ¿Qué Es la Ciencia de Datos?
- 2 ¿Por Qué Nos Importa?
- 3 Parámetros Objetivo: ¿Qué Estamos Buscando?
- 4 Regresión: Nuestro Primer Estimador
- 5 Más Allá de la Regresión
- 6 Sobre el Curso**
- 7 Repaso

Lo Que Viene Después

Parte 1 (esta parte):

- ▶ Regresión lineal y los objetivos f^* y ATT
- ▶ Validación cruzada y generalización
- ▶ Error de predicción y el *trade-off* sesgo-varianza

Parte 2:

- ▶ Lasso: regularización y selección de variables
- ▶ Árboles de decisión y bosques aleatorios
- ▶ Bosques causales para efectos de tratamiento heterogéneos
- ▶ Mismos objetivos, estimadores alternativos

Parte 3:

- ▶ Texto como datos: limpieza, tokenización, *embeddings*
- ▶ Modelado de tópicos y clasificación de texto

Estructura del Curso

Sesiones

lunes y miércoles, 2:00–3:20 pm

- ▶ **Lunes:** clases de teoría
- ▶ **Miércoles:** sesiones de laboratorio

Equipo

- ▶ Ignacio Sarmiento-Barbieri
- ▶ Julián David Rojas Aguilar
asistente de docencia

Todo el material y las entregas van por
Bloque Neón.

Talleres: video (15 min) + repositorio de código + registro de la conversación con el agente + scripts reproducibles

Evaluación

- ▶ 3 Quizzes $\times 7\% = 21\%$
individuales, en línea, con LockDown Browser
- ▶ 3 Talleres grupales $\times 17\% = 51\%$
incluyen evaluación por pares
- ▶ Proyecto final = 20%
- ▶ Participación = 8%

Lo Que Esperamos de Ustedes

- ▶ Asistir y participar
- ▶ Programar
- ▶ Colaborar y aprender de pares
- ▶ Usar agentes de IA con criterio

Lo Que Dejamos Afuera

No cubrimos series de tiempo.

- ▶ Todo en este curso supone que las observaciones son intercambiables (i.i.d. o paneles cortos)
- ▶ Las series de tiempo rompen ese supuesto — y merecen su propio curso

Misma lógica para la **econometría espacial**: supuestos distintos, caja de herramientas distinta.

Pero las herramientas se transfieren. Regularización, validación cruzada, sesgo-varianza, pensar en términos de objetivos. Son las bases que usarían para estudiar series de tiempo más adelante.

Agenda

- 1 ¿Qué Es la Ciencia de Datos?
- 2 ¿Por Qué Nos Importa?
- 3 Parámetros Objetivo: ¿Qué Estamos Buscando?
- 4 Regresión: Nuestro Primer Estimador
- 5 Más Allá de la Regresión
- 6 Sobre el Curso
- 7 Repaso

Repaso

Dos Preguntas, un Solo Lenguaje

1. La ciencia de datos combina preguntas relevantes para los economistas

- ▶ **Aprendizaje de Máquinas** $\rightarrow$ *predecir*. Objetivo: $f^*(x) = \mathbb{E}[Y \mid X = x]$. Éxito: error fuera de muestra.
- ▶ **Econometría** $\rightarrow$ *medir*. Objetivo: β , el ATT. Éxito: identificación e inferencia.

2. Pero se estudian con el mismo lenguaje

OBJETIVO	$\rightarrow$	ESTIMADOR	$\rightarrow$	ALGORITMO
qué queremos		cómo lo logramos		cómo se calcula

3. La regresión lineal es nuestro primer estimador

Próxima clase: hablar de IA, los agentes y Claude Code