

Agentes en la Ciencia de Datos

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Adaptado de Scott Cunningham, *AI Methods for Research Workers* (MIT, 2026)

Agenda

- 1 El marco conceptual
- 2 Ganancias y Peligros
- 3 Configuración y fundamentos
- 4 Conclusion

La función de producción humano e IA

$$Q = f(H, M)$$

- ▶ H = tiempo humano
- ▶ M = tiempo de máquina


La pregunta no es *si* usar M . Es cuánto H utilizamos intencionalmente.

La investigación autónoma ya estaba aquí

El **Project APE** del Social Catalyst Lab ha producido más de **1,000** artículos empíricos de política generados de forma autónoma.

Agentes que:

- ▶ extraen datos públicos
- ▶ corren diseños empíricos
- ▶ escriben artículos completos



Rating ELO: artículos de APE vs. artículos humanos.

Yo lo hice

Tengo un manuscrito para una clase esta tarde. Olvidé qué propuse. Mis intereses de investigación son: economía urbana, con énfasis en discriminación de mercados de vivienda y seguridad pública, me interesan métodos de inferencia causal con aplicaciones de machine learning. Idea la pregunta de investigación. Debe ser sustantiva --- una cuestión de importancia moral y económica Encuentra todas las fuentes de datos apropiadas. Bájalas a carpetas locales. Organiza todo en un pipeline replicable Elige una estrategia de identificación, una población, un estimando, un estimador. Estímalo. Corre pruebas de robustez Reporta resultados con exhibiciones retóricamente apropiadas --- figuras hermosas, tablas hermosas Escribe el manuscrito en la voz y el estilo de Lawrence Katz, Deirdre McCloskey, y Roger Koenker, mis escritores económicos favoritos. Cada oración debe sentirse trabajada --- científicamente precisa, moralmente densa, apenas contenida 22 páginas, a doble espacio. La primera oración debe capturar de inmediato la atención del lector y hacer que quiera leer la segunda, luego el primer párrafo, y así sucesivamente No exagere. Di la verdad.

El artículo

A Gradient, Not a Jump. What the Redlining Maps Predict, and What They Caused, at Their Own Borders

Predecir no es lo mismo que causar

El hecho

En los años 30 el gobierno pintó de **rojo** los barrios que consideraba “peligrosos” (casi siempre donde vivían familias afroamericanas o pobres). Hoy esos barrios **siguen siendo más pobres**. La correlación es enorme y real.

Historia 1: la línea *causó* el destino

Barrios iguales; marcar uno de rojo le cortó el crédito y la profecía se cumplió sola.

El daño lo hizo el mapa.

Historia 2: la línea solo *registró*


El barrio ya venía peor por otras razones; el mapa dibujó las líneas *alrededor* de lo que ya existía.

El mapa no causó nada.

Las dos predicen la misma foto de hoy. Se distinguen en un solo lugar: la frontera.

El artículo

A Gradient, Not a Jump. What the Redlining Maps Predict, and What They Caused, at Their Own Borders



El artículo


A Gradient, Not a Jump. What the Redlining Maps Predict, and What They Caused, at Their Own Borders

La prueba: los dos lados de la misma raya Comparo **dos casas pegadas**, misma cuadra, mismo aire — pero una quedó del lado **rojo** y la otra del lado **amarillo**, por el capricho del lápiz.

- ▶ Si el mapa **causó** el destino $\Rightarrow$ las vecinas deberían ser muy distintas hoy (un **salto** justo en la raya).
- ▶ Si el mapa **solo registró** $\Rightarrow$ las vecinas deberían ser casi iguales (**sin salto**).

El artículo

A Gradient, Not a Jump. What the Redlining Maps Predict, and What They Caused, at Their Own Borders



El artículo

A Gradient, Not a Jump. What the Redlining Maps Predict, and What They Caused, at Their Own Borders


Lo que encuentro

Las casas a ambos lados de la raya son **casi iguales**: no hay salto. La desigualdad ya estaba en el terreno *antes* de que dibujaran la línea. El mapa fue **un síntoma, no la enfermedad**.

Ojo: esto **no** dice que el redlining fue inofensivo. Comparar los dos bordes de *una* raya no mide el efecto de *todo* el sistema de discriminación; solo dice que esa raya, en su borde, no produjo el salto que se le atribuye.

El artículo

A Gradient, Not a Jump. What the Redlining Maps Predict, and What They Caused, at Their Own Borders



Tres veces, como lavar plata

Lo que realmente hice no estuvo ni cerca de ser totalmente automatizado.


Cuando el manuscrito regresó, lo metí en otra **IA**, descargué el reporte en markdown, le pedí a Claude que atendiera cada comentario, tomé el nuevo borrador y lo volví a meter a esta **IA**.

Tres veces. Como si estuviera lavando dinero.

Agenda

- 1 El marco conceptual
- 2 Ganancias y Peligros
- 3 Configuración y fundamentos
- 4 Conclusion

Caso I: mantener el esfuerzo constante, ganancia asegurada




Mantener H^* igual. Más y mejor trabajo en las mismas horas.

- Mayores ganancias en producto.
- Capital humano preservado.

Esto requiere no tomar todo el ahorro de tiempo.

Caso II: ahorrar tiempo e igual producto




Recortar horas, pero quedarnos en la zona verde. Mientras $H > \bar{H}$, el producto se mantiene por encima de la línea base.

- ▶ Ahorro de tiempo moderado.
- ▶ Aún una ganancia neta en producto.

Algo de holgura está bien. La curva subió lo suficiente para absorberla.

Caso III: la zona peligrosa



La zona de peligro. La depreciación de habilidades sin el esfuerzo para mantener $H > \bar{H}$ implica $Q_{post} < Q_{pre}$.

► Peor que antes de la IA.

El punto no es evitar el ahorro de tiempo. El punto es ser intencional.

No confíes en nada y verifícalo todo

The New York Times

A.I. ‘Hallucinations’ Created Errors in Court Filing, Top Law Firm Says

Sullivan & Cromwell apologized for submitting a court document that had fake citations created by artificial intelligence.

Listen · 4:38 min

Share full article



426



Lawyers for Sullivan & Cromwell apologized for submitting a court filing that had fake citations created by artificial intelligence. John Taggart for The New York Times



By Santul Nerkar

April 21, 2026

No confíes en nada y verifícalo todo

Lo llamativo es que la capacitación en IA de la firma *ya* incluía la regla:

**No confíes en nada
Verifícalo todo**

La regla era correcta. El flujo de trabajo aun así falló.

Producción y verificación son tareas distintas

Imaginen su trabajo como una serie de carpetas llenas de archivos que manipulas en dos tareas distintas:

Producción

Generar borradores, código, tablas, simulaciones, resúmenes de literatura, slides y versiones alternativas.

Verificación

Saber si el resultado es verdadero, fiel, correctamente estimado y digno de creerse.

Históricamente venían empaquetadas juntas. Los agentes de IA las están separando.

La ventaja comparativa en producción varía entre individuo y cambia con el tiempo. Pero el camino de la idea al producto final está siendo reconfigurado por los agentes.

Agenda

- 1 El marco conceptual
- 2 Ganancias y Peligros
- 3 Configuración y fundamentos**
- 4 Conclusion

Los agentes son distintos porque actúan

Un espectro de uso de IA, de pasivo a autónomo:



Un **agente** lee archivos, escribe código, lo ejecuta, lee la salida y decide qué hacer después. No es un chatbot con mejor prosa: **actúa sobre tu proyecto.**

<code>ls data/</code>	listar archivos
<code>rg "salario" .</code>	buscar texto y código
<code>Rscript estimar.R</code>	correr un script de R
<code>quarto render</code>	compilar un cuaderno
<code>git diff</code>	inspeccionar cambios

Claude Code empezó como un agente de terminal

Boris Cherny se unió a Anthropic en 2024. A finales de ese año le dio a Claude acceso directo a su terminal y le pidió arreglar sus playlists de Spotify.

Claude escribió llamadas a la API, leyó su propia salida, manejó errores y terminó el trabajo de forma autónoma. *Esa fue la prueba de concepto.*

- ▶ **Finales de 2024.** Prototipo interno.
- ▶ **24 feb 2025.** Vista previa de investigación con Claude 3.7 Sonnet.
- ▶ **Mayo 2025.** Disponibilidad general.
- ▶ **25 nov 2025.** Claude Code llega dentro de la app de escritorio.

La integración de Claude Code en el escritorio es a los agentes de IA lo que ChatGPT fue a GPT: el producto, no la capacidad, es probablemente el héroe no reconocido de esta revolución.

Instala Claude Code pidiéndole a Claude que lo instale

Tienes que llevar Claude Code a tu máquina de algún modo. El comando de instalación es el primer lugar donde el phishing te busca.

El problema del caballo de Troya

- ▶ sitios clonados que imitan `claude.ai`, GitHub, docs de paquetes
- ▶ botones de “copiar” que ocultan un comando distinto al mostrado
- ▶ pegar un comando de instalación desconocido es malware voluntario

El hábito defensivo

- ▶ abre la app de escritorio (u otro agente en el que confíes)
- ▶ dale la URL que ibas a pegar
- ▶ pídele que inspeccione el dominio, el repo, el comando y lo explique
- ▶ no ejecutes nada hasta que la explicación coincida con lo que esperas

Anthropic actualmente lo hace mejor que la mayoría en no ser clonado. Eso no durará. Construye el hábito antes de que la carrera armamentista te alcance.

Un agente, dos ventanas

Terminal y escritorio no son dos productos. **Es el mismo agente:** mismo modelo, mismas herramientas, mismo CLAUDE.md. Lo que cambia es la ergonomía, no la capacidad.

Si la tarea es...	Dónde	Por qué
Correr un .R, compilar, git commit	CLI	Ahí vive tu <i>toolchain</i> local
Ver qué cambió antes de aceptarlo	Escritorio	Diffs visuales lado a lado
Larga y desatendida	CLI	Se lanza, se deja corriendo
Conversar, leer un PDF, organizar	Escritorio	No necesita toolchain
Automatizar (script, cron, CI)	CLI	Es lo único automatizable

Tres modos de operación

Modo	Qué hace	Dónde
Plan	Solo lectura. Busca, lee, propone. Sin cambios de estado.	CLI y Escritorio
Acción	Edita, corre, escribe. Cada llamada riesgosa pide aprobación.	CLI y Escritorio
--dangerously-skip-permissions	Edita, corre, escribe — sin aprobaciones. El agente corre libre.	Solo CLI, pero existe BypassPermissions

Por qué importa el tercer modo: el agente va rápido. Lanza una tarea larga, aléjate, vuelve a un resultado terminado. No disponible en la app de escritorio. Has renunciado al punto de control por herramienta, así que la pregunta de seguridad ya no es el flag — es el radio de impacto de la carpeta.

Tres capas para configurar un agente

Todo lo que le dicen a un agente cae en una de tres capas. No se distinguen por lo que dicen, sino por **cuándo se activan**.

Capa	Se activa	Ejemplo
CLAUDE.md	Siempre, al abrir el proyecto	<i>"Los datos de 01_Datos/01_Crudos/nunca se modifican"</i>
Skill	Cuando aplica: el agente decide	<code>.claude/skills/reporte-regresion/SKILL.md</code>
Comando	Cuando lo pido: yo decido	<code>.claude/commands/limpiar.md</code> → <code>/limpiar ventas.csv</code>

CLAUDE.md es la constitución del proyecto

Es el archivo que el agente lee al abrir la carpeta. **No hay magia:** su contenido se pega al principio de la conversación. Es *contexto*, no configuración. Tres consecuencias que no son obvias:

- ▶ **Ocupa espacio.** 500 líneas de reglas se comen el contexto que necesitás para el trabajo real. Más largo $\neq$ mejor.
- ▶ **No es una garantía.** Es una instrucción muy bien ubicada, no una restricción del sistema. Si la regla importa de verdad, además necesitás permisos, respaldos o `git`.
- ▶ **Si se contradice, pierde.** Reglas vagas o en conflicto se ignoran. “*Escribí buen código*” no dice nada; “*usá `data.table`, no `dplyr`*” sí.

CLAUDE.md: qué va y qué no

Sí va	No va
Cómo se corre y se compila esto	Explicar qué es una regresión
Estructura de carpetas y qué es sagrado	Copiar la documentación de un paquete
Convenciones que no se deducen del código	Lo que ya está escrito en el código
Qué NUNCA hacer sin preguntar	Historia de decisiones viejas
El comando de verificación	Aspiraciones vagas de calidad

Lee este repo y redactá un CLAUDE.md de cómo deberíamos trabajar.
Preguntame antes de escribir la versión final.

El test: ¿le pasarías este archivo a un practicante nuevo en su primer día? Si sí, está bien escrito. Si es una lista de deseos, no. **Fallas típicas:** la novela de 800 líneas, reglas que se contradicen, reglas no verificables, y el archivo que nadie actualizó.

Una skill es un procedimiento reutilizable

CLAUDE.md dice cómo funciona *este proyecto*. Una **skill** dice cómo se hace *esta tarea*. Es una carpeta con un SKILL.md:

```
---
name:  reporte-regresion
description:  Corre una regresión lineal en R y devuelve una tabla de
resultados ordenada. Usar cuando se pida estimar un
modelo OLS y ver coeficientes, errores estándar y R2.
---

1.  Ajustar el modelo con lm().
2.  Coeficientes con broom::tidy(), ajuste con broom::glance().
3.  Redondear a 3 decimales y explicar qué mide cada coeficiente.
```

Lo no obvio: el description es lo único que el agente lee para decidir si la skill aplica; el cuerpo se carga solo si decide usarla. Una skill con mala descripción es una skill que nunca se ejecuta.

Los comandos

Un **comando** lo disparás el usuarion, por nombre. Unos ya vienen; otros los escribes (el .md de la slide anterior).

/help	qué existe <i>en tu versión</i> — la fuente de verdad
/init	genera un primer CLAUDE.md leyendo el repo
/context	cuánto contexto estás gastando
/clear	empezar limpio cuando la sesión se enredó
/permissions	qué puede hacer sin preguntarte

Agenda

- 1 El marco conceptual
- 2 Ganancias y Peligros
- 3 Configuración y fundamentos
- 4 Conclusion

La verificación es el nuevo cuello de botella

Los agentes hacen la producción lo bastante barata como para separarla de la verificación.



El cuello de botella se mueve. La parte difícil ya no es producir primeros borradores, primeras regresiones o primeros resúmenes.

La parte difícil es diseñar sistemas de verificación que sobrevivan a la producción barata.