

Regresión y Causalidad

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

- 1 Repaso: Objetivo, Estimador, Estimación
- 2 MCO: Qué Estima
- 3 Regresión y Efecto Causal
- 4 Cierre

Dónde Quedamos

En la primera clase separamos tres cosas que se confunden todo el tiempo:

Objetivo	La cantidad verdadera que queremos conocer
Estimador	El procedimiento que aplicamos a los datos
Estimación	El número que sale de nuestra muestra

Y nombramos dos objetivos que van a acompañarnos todo el semestre:

- **Predecir.**
- **Estimar efectos causales.**

La Pregunta de Hoy

Ya sabemos que la regresión es *un* estimador de esos dos objetivos. Falta lo importante:

¿Cuándo el coeficiente de una regresión es el efecto causal,
y qué hay que hacer para que lo sea?

El recorrido de hoy:

- 1 **MCO**: qué estima.
- 2 **Inferencia**: cuánta confianza merece ese número.
- 3 **Identificación**: qué supuesto convierte el coeficiente en un efecto causal.

Agenda

- 1 Repaso: Objetivo, Estimador, Estimación
- 2 MCO: Qué Estima
- 3 Regresión y Efecto Causal
- 4 Cierre

El Modelo Lineal, en Notación Matricial

Datos $\{(y_i, x_i)\}_{i=1}^n$, apilados:

$$\underbrace{Y}_{n \times 1} = \underbrace{X}_{n \times k} \underbrace{\beta}_{k \times 1} + \underbrace{\epsilon}_{n \times 1}$$

El Modelo Lineal, en Notación Matricial

Lineal en los parámetros, no en las variables. Estos tres modelos son todos lineales para MCO:

- ▶ $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \epsilon$
- ▶ $\log(y) = \beta_0 + \beta_1 \log(x) + \epsilon$
- ▶ $y = \beta_0 + \beta_1 x + \beta_2 d + \beta_3 (x \cdot d) + \epsilon$

La restricción está en cómo entran los β , no en cómo entran los datos.

$\hat{\beta}$ en Una Slide

MCO elige el β que minimiza la suma de residuos al cuadrado:

$$\hat{\beta} = \arg \min_b (Y - Xb)'(Y - Xb)$$

Lo único que se necesita: $\text{rango}(X) = k$. Si dos columnas son combinación lineal una de otra (colinealidad perfecta), $X'X$ no se invierte.

Que $\hat{\beta}$ sea causal es una propiedad del **diseño**, no del **algoritmo**.

Interpretar el Número

Regresión del Laboratorio 1

Con los datos del laboratorio 01 estimé $\text{Precio}_i = \alpha + \beta_1 \text{Odómetro}_i + \epsilon_i$ y obtuve:

$$\widehat{\text{Precio}}_i = \underset{(256,8)}{9.528,7} - \underset{(0,0019)}{0,0273} \text{Odómetro}_i, \quad n = 715$$

Tres lecturas posibles del **mismo** $\hat{\beta}_1$:

- **Descriptiva:** en estos datos, los autos con más millas se venden más baratos, unos 27 dólares menos cada 1.000 millas.
- **Predictiva:** si me dicen el odómetro de un auto que no vi, esta es mi mejor predicción sobre su precio.
- **Causal:** si a *este* auto le sumara 1.000 millas, su precio caería 27 dólares.

Los Supuestos Detrás de Esos Números

Supuesto	Qué le compra
Muestra aleatoria	Que la muestra represente a la población de interés
$\mathbb{E}[\epsilon X] = 0$ (exogeneidad)	Insesgadez: $\mathbb{E}[\hat{\beta}] = \beta$.
$\mathbb{V}(\epsilon X) = \sigma^2 I$ (homocedasticidad)	La fórmula estándar del error estándar, y que MCO sea el mejor entre los lineales insesgados (BLUE)
n grande	Que t y los intervalos usen la normal, sin necesidad de suponer errores normales

Cuando la Varianza No Es Constante

La homocedasticidad casi nunca se cumple en datos económicos: la dispersión de los salarios crece con la educación, la de los precios con el tamaño de la casa.

Eso **no** sesga a $\hat{\beta}$. Rompe la fórmula del error estándar. La solución es cambiar la fórmula, no el estimador. La homocedástica supone un único σ^2 ; la robusta lo estima dato a dato:

$$\underbrace{\hat{V}(\hat{\beta}) = \hat{\sigma}^2(X'X)^{-1}}_{\text{homocedástica}}$$

-
- Los coeficientes no cambian. Cambian los errores estándar, los t y los intervalos.

La Inferencia No Arregla el Sesgo

Un intervalo de confianza angosto alrededor del número equivocado sigue siendo el número equivocado.

- ▶ Más datos reducen la **varianza**. No tocan el **sesgo**.
- ▶ Un p -valor de 0,001 dice que el número es distinto de cero. No dice de qué número se trata.
- ▶ Con n suficientemente grande, cualquier sesgo, por chico que sea, sale “significativo”.

Por eso la pregunta de identificación va **antes** que la de inferencia.

Agenda

- 1 Repaso: Objetivo, Estimador, Estimación
- 2 MCO: Qué Estima
- 3 Regresión y Efecto Causal**
- 4 Cierre

El Problema Fundamental


- ▶ Resultados potenciales

- ▶ $Y_i(1)$ Resultado potencial si recibe el tratamiento: $T = 1$

- ▶ $Y_i(0)$ Resultado potencial si **NO** recibe el tratamiento: $T = 0$

- ▶ El efecto individual $\tau_i = Y_i(1) - Y_i(0)$ **no se observa nunca**: de cada persona vemos uno de los dos mundos, jamás los dos.

El Problema Fundamental



- El efecto individual $\tau_i = Y_i(1) - Y_i(0)$ **no se observa nunca**: de cada persona vemos uno de los dos mundos, jamás los dos.

El Problema Fundamental

Lo que sí podemos perseguir son *promedios*:

- ▶ **ATE** = $\mathbb{E}[\tau_i]$: el efecto para un usuario *al azar*. “¿Conviene implementar el programa a todos los individuos?”
- ▶ **ATT** = $\mathbb{E}[\tau_i \mid T = 1]$: el efecto para quienes *sí* recibieron el tratamiento. “¿Funcionó en quienes efectivamente lo recibieron?”

No son el mismo número, salvo que el efecto sea homogéneo. Cuál de los dos quiere es una pregunta de resolver por el tomador de decisiones, no de estadística.

Elegir el estimando viene **antes** que elegir el estimador.

Lo Que Sí Podemos Calcular

Observamos $Y(1)$ para los tratados y $Y(0)$ para los controles. Con eso, lo único que sale directo de los datos es la **comparación ingenua**:

$$\Delta = \mathbb{E}[Y \mid T = 1] - \mathbb{E}[Y \mid T = 0]$$

Y esa es exactamente la cantidad que estima $\hat{\beta}_1$ en

$$Y = \beta_0 + \beta_1 T + \epsilon$$

Δ compara *personas distintas*: los tratados contra los controles. El **ATT** compara los *dos mundos de las mismas personas*. No son lo mismo, y no tienen por qué coincidir.

La pregunta clave:
¿cuánto se parece Δ al ATT?

$\hat{\beta}_1$ Es la Diferencia de Medias

Tome la esperanza condicional de $Y = \beta_0 + \beta_1 T + \epsilon$ en los dos valores de T , **sin suponer nada** sobre ϵ :

$$\mathbb{E}[Y \mid T=1] = \beta_0 + \beta_1 + \mathbb{E}[\epsilon \mid T=1],$$

$$\mathbb{E}[Y \mid T=0] = \beta_0 + \mathbb{E}[\epsilon \mid T=0].$$

Restando:

$$\Delta = \beta_1 + \underbrace{(\mathbb{E}[\epsilon \mid T=1] - \mathbb{E}[\epsilon \mid T=0])}_{\text{sesgo de selección}}$$

Δ Le Presta a los Tratados el $Y(0)$ de los Controles

Lo que queríamos medir en los tratados es

$$\mathbb{E}[Y(1) \mid T=1] - \underbrace{\mathbb{E}[Y(0) \mid T=1]}_{\text{no existe en los datos}}$$

Ese segundo término no es difícil de estimar: **no está**. Nadie observó a un tratado sin tratar. Lo que hace Δ es reemplazarlo por lo único parecido que sí tenemos:

$$\mathbb{E}[Y(0) \mid T=1] \longrightarrow \mathbb{E}[Y(0) \mid T=0]$$

Los controles se usan como el “yo sin tratar” de los tratados. Eso no es una aproximación que mejore con más datos: es una **construcción**, y hay que defenderla. Si la empresa mostró la versión nueva primero a sus usuarios más activos, el préstamo ya nació viciado.

Si el préstamo es legítimo, Δ es el efecto.
Ningún tamaño de muestra decide eso.

Ese Término Compara los $Y(0)$ de los Dos Grupos

Quedó pendiente qué es, exactamente, $\mathbb{E}[\epsilon \mid T=1] - \mathbb{E}[\epsilon \mid T=0]$.

En $Y = \beta_0 + \beta_1 T + \epsilon$ con efecto constante, poner $T = 0$ deja:

$$Y(0) = \beta_0 + \epsilon$$

Es decir, ϵ es $Y(0)$ menos una constante. Al restar entre los dos grupos, la constante se cancela:

$$\mathbb{E}[\epsilon \mid T=1] - \mathbb{E}[\epsilon \mid T=0] = \mathbb{E}[Y(0) \mid T=1] - \mathbb{E}[Y(0) \mid T=0]$$

Ese término mide exactamente cuánto falla el préstamo. Es cero si los controles eran, en promedio, un buen “yo sin tratar” de los tratados.

Con efecto heterogéneo la cuenta es la misma, cambiando β_1 por el ATT.

El Experimento Corta la Selección

El problema era este préstamo:

$$\mathbb{E}[Y(0) \mid T=1] \longrightarrow \mathbb{E}[Y(0) \mid T=0]$$

En un experimento el tratamiento se sortea, así que no hay ninguna fuerza que mande al tratamiento a usuarios con mayor o menor $Y(0)$:

$$T \perp (Y(0), Y(1)) \implies \mathbb{E}[Y(0) \mid T=1] = \mathbb{E}[Y(0) \mid T=0]$$

El sesgo de selección es **exactamente** cero, y entonces

$$\Delta = ATT = ATE$$

La segunda igualdad: los tratados son una muestra al azar de la población.

Balance en Esperanza No Es Balance Exacto

Todo lo anterior es sobre la **población**. En una muestra concreta las cosas no salen exactas.

Lo que la identificación necesita es balance en $Y(0)$:

$$\mathbb{E}[Y(0) \mid T=1] = \mathbb{E}[Y(0) \mid T=0]$$

Eso **no se puede chequear**: el $Y(0)$ de los tratados no está en los datos.

Lo que sí se puede chequear es el balance en las covariables medidas *antes* del tratamiento. En esta muestra $\bar{X}_1 - \bar{X}_0$ no va a dar exactamente cero: el sorteo no promete eso. Promete que el desbalance no sea sistemático,

$$\mathbb{E}_{\text{sorteo}}[\bar{X}_1 - \bar{X}_0] = 0$$

donde la esperanza es sobre las asignaciones posibles.

El desbalance accidental existe.

Lo que no existe, bajo sorteo, es desbalance **sistemático**.

Muestra Finita y Muestra Grande

En los datos no calculamos Δ sino su análogo muestral, que es el mismo número que $\hat{\beta}_1$:

$$\hat{\Delta} = \bar{Y}_1 - \bar{Y}_0$$

Bajo aleatorización, ese estimador tiene dos propiedades distintas:

- ▶ **Insesgadez.** $\mathbb{E}_{\text{sorteo}}[\hat{\Delta}] = \text{ATT}$. El sorteo no empuja a $\hat{\Delta}$ en ninguna dirección. Vale para *cualquier* n , incluso chico.
- ▶ **Consistencia.** $\hat{\Delta} \xrightarrow{p} \text{ATT}$. El desbalance accidental se achica a medida que crece n .

Con n chico $\hat{\Delta}$ ya apunta al lugar correcto.
Lo que la muestra grande agrega es **puntería**, no dirección.

Con Experimento, los X Compran Precisión

Supongamos que $\mathbb{E}[\epsilon \mid T] = 0$ **sin** controles, porque el tratamiento se sorteó:

$$Y = \beta_0 + \beta_1 T + \epsilon \quad \longrightarrow \quad Y = \beta_0 + \beta_1 T + \gamma' X + \tilde{\epsilon}$$

Sobre el sesgo, nada: no hay sesgo que corregir. Lo que cambia es la varianza.

$$\underbrace{\mathbb{V}(\hat{\beta}_1) = \frac{\sigma_\epsilon^2}{n \mathbb{V}(T)}}_{\text{sin } X} \quad \longrightarrow \quad \underbrace{\mathbb{V}(\hat{\beta}_1) = \frac{\sigma_{\tilde{\epsilon}}^2}{n \mathbb{V}(T) (1 - R_{T \sim X}^2)}}_{\text{con } X}$$

Dos cosas se movieron: el numerador cambió de σ_ϵ^2 a $\sigma_{\tilde{\epsilon}}^2$, y al denominador le apareció el factor $(1 - R_{T \sim X}^2)$. Hay que mirarlas por separado.

Con Experimento, los X Compran Precisión

$$\mathbb{V}(\hat{\beta}_1) = \frac{\sigma_{\tilde{\epsilon}}^2}{n \mathbb{V}(T) (1 - R_{T \sim X}^2)}$$

- El **denominador** no se mueve: bajo aleatorización T es independiente de X , así que $R_{T \sim X}^2 \approx 0$. Los controles no le quitan variación al tratamiento. (*Fuera del experimento sí se mueve, y para el lado malo.*)
- El **numerador** sí baja, y no es una promesa sino una identidad: $\tilde{\epsilon}$ es ϵ después de sacarle lo que X explica.

$$\sigma_{\tilde{\epsilon}}^2 = \sigma_{\epsilon}^2 (1 - R_X^2), \quad R_X^2 \equiv \text{fracción de la varianza de } \epsilon \text{ que } X \text{ explica}$$

El error estándar (“ee”) es la raíz de la varianza, y el denominador no cambió. Entonces:

$$\frac{\text{ee}(\hat{\beta}_1) \text{ con } X}{\text{ee}(\hat{\beta}_1) \text{ sin } X} = \frac{\sigma_{\tilde{\epsilon}}}{\sigma_{\epsilon}} \approx \sqrt{1 - R_X^2}$$

Cuánta Precisión, Exactamente

$$\frac{\text{ee con } X}{\text{ee sin } X} \approx \sqrt{1 - R_X^2}$$

Supongamos que los controles explican el 36% de la varianza que quedaba:

$$\sqrt{1 - 0,36} = 0,80 \quad \implies \quad \text{el ee cae un 20\%}$$

Y como el error estándar cae con $\sqrt{n}$, ese 0,80 es exactamente lo que habría comprado agrandar la muestra un 56% ($1/0,80^2 = 1,56$): controles gratis en lugar de un 56% más de encuestas.

Agenda

- 1 Repaso: Objetivo, Estimador, Estimación
- 2 MCO: Qué Estima
- 3 Regresión y Efecto Causal
- 4 Cierre

El Mismo $\hat{\beta}$, Tres Lecturas

Lectura	Qué exige	Cómo se defiende
Descriptiva	Nada, más allá de datos limpios	Reportando la muestra y la especificación
Causal	Aleatorización, o suponer cero el sesgo de selección	Con el diseño y conocimiento del contexto
Predictiva	Que los datos nuevos vengan del mismo proceso	Con desempeño fuera de muestra

El algoritmo es el mismo en los tres casos.
Lo que cambia es qué está usted dispuesto a suponer.

Lo Que Viene

- ▶ **Clase 4 (miércoles, laboratorio).** Vamos a implementar esto, a mano sin Claude, necesitamos construir capital humano
- ▶ **Clase 5 (lunes, festivo).** Tarea para la casa, con Claude.

Apéndice: Otros Principios de Estimación

Hoy derivamos $\hat{\beta}$ minimizando errores al cuadrado. No es el único camino.

- ▶ **Máxima verosimilitud:** se supone una distribución para los datos y se elige el parámetro que hace más probable lo observado. Con errores normales, el estimador de máxima verosimilitud de β coincide con MCO.
- ▶ **Método de momentos:** se reemplazan momentos poblacionales por sus análogos muestrales. Es lo que hicimos, en realidad, al pasar de $\mathbb{E}[(Y - X'b)^2]$ a la suma en la muestra.

La verosimilitud vuelve a aparecer cuando el resultado no es continuo, por ejemplo al clasificar documentos.