

Predecir y Explicar: Dos Problemas Distintos

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

- 1 Repaso: Tres Lecturas Posibles
- 2 El Objeto de Estimación Predictivo
- 3 La Regresión Lineal Aproxima la CEF
- 4 Predecir
- 5 Intuición: Sesgo y Varianza
- 6 Cierre

El Mismo $\hat{\beta}$, Tres Lecturas Posibles

Lectura	Qué exige	Cómo se defiende
Descriptiva	Nada, más allá de datos limpios	Reportando la muestra y la especificación
Causal	Aleatorización, o suponer cero el sesgo de selección	Con el diseño y conocimiento del contexto
Predictiva	Que los datos nuevos vengan del mismo proceso	Con desempeño fuera de muestra

Hoy: qué significa, exactamente, “desempeño fuera de muestra”.

La Causal Ya la Ganamos: Karlan y List

- ▶ El diseño hace el “heavy lifting”:

$$\begin{aligned} T \text{ aleatorio} &\Rightarrow \mathbb{E}[Y(0) \mid T=1] = \mathbb{E}[Y(0) \mid T=0] \\ &\Rightarrow \Delta = \text{ATE} \end{aligned}$$

- ▶ El sesgo de selección desaparece por el diseño (no por un supuesto)

- ▶ Los resultados:

- ▶ $n = 47.114$ donantes
- ▶ Balance conjunto: $p = 0,395$
- ▶ $\hat{\beta}_1 = 0,0047$ (ee 0,0014)
- ▶ Donan 1,77% vs. 2,24%

¿Qué hace que un modelo lineal **prediga bien**?

Roadmap:

- 1 El objeto: si el problema es predecir, ¿cuál es el parámetro objetivo (estimando)?
- 2 El estimador: la regresión lineal como maquinaria para perseguirla.
- 3 La estimación: ¿es buena la predicción?

Agenda

- 1 Repaso: Tres Lecturas Posibles
- 2 El Objeto de Estimación Predictivo**
- 3 La Regresión Lineal Aproxima la CEF
- 4 Predecir
- 5 Intuición: Sesgo y Varianza
- 6 Cierre

Otro Problema, Otro Objeto

	Problema causal	Problema predictivo
La pregunta	¿Qué pasa con Y si nuevo T ?	¿Cuánto vale Y para un X que acaba de llegar ?
El objeto	Un número : β_1 , el ATE	Una función : la que convierte un x nuevo en la mejor adivinanza de Y

Llega un carro que no estaba en los datos, con odómetro x . Hay que entregar un precio. Ese “hay que entregar” define el problema.

El **problema** define el **objeto de estimación**.
El algoritmo (MCO) puede ser el mismo.

Aprendizaje Supervisado

$$y = f(X) + \epsilon$$


- ▶ El problema de aprender y a partir de un conjunto de características (*features*) X se conoce como una tarea de **aprendizaje supervisado**.
- ▶ y es la que **supervisa** el aprendizaje.
- ▶ Para predecir, f en sí misma no nos interesa. La podemos tratar como una **caja negra**: cualquier aproximación $\hat{f}$ que entregue una buena predicción alcanza.

Lo que funciona, funciona.

¿Qué Es Predecir Bien? La Función de Pérdida

Predicción $\hat{Y}$, realidad Y . Equivocarse cuesta, y el costo lo medimos con una **función de pérdida** $L(Y, \hat{Y})$. Nosotros usaremos:

$$L(Y, \hat{Y}) = (Y - \hat{Y})^2$$



El Mejor Predictor Posible

Buscamos la función que minimiza la pérdida esperada, sin restringirnos a ninguna familia:

$$f^* = \arg \min_g \mathbb{E}[(Y - g(X))^2]$$

Lo Que Ni el Mejor Predictor Supera


Definamos el error respecto del mejor predictor:

$$\epsilon \equiv Y - f^*(X) \quad \implies \quad Y = f^*(X) + \epsilon$$

Agenda

- 1 Repaso: Tres Lecturas Posibles
- 2 El Objeto de Estimación Predictivo
- 3 La Regresión Lineal Aproxima la CEF**
- 4 Predecir
- 5 Intuición: Sesgo y Varianza
- 6 Cierre


Volvamos a los Carros




Puntos rojos: precio promedio por decil de odómetro (la CEF empírica). Recta: MCO del Laboratorio 1,
 $\widehat{\text{Precio}} = 9.528,7 - 0,0273 \text{ Odómetro}, n = 715.$

Lineal en Parámetros, Flexible en Variables

$$\text{Precio} = \beta_0 + \beta_1 \text{Odo} + \beta_2 \text{Dealer} + \beta_3 (\text{Odo} \times \text{Dealer}) + \epsilon$$



Subiendo el Grado




¿Qué pasa con el R^2 **dentro de muestra** al subir el grado del polinomio?

Agenda

- 1 Repaso: Tres Lecturas Posibles
- 2 El Objeto de Estimación Predictivo
- 3 La Regresión Lineal Aproxima la CEF
- 4 Predecir**
- 5 Intuición: Sesgo y Varianza
- 6 Cierre


Un ejemplo para construir intuición

Diez carros de la muestra y la recta de MCO.



¿Qué sucede con cinco carros que llegaron después?


Mismos diez carros, misma recta. Ahora llegan cinco carros que el modelo **nunca vio**.




Llenos: los 10 del ajuste. Vacíos: los 5 nuevos, con su error punteado.

El Ajuste Perfecto Existe

Cambiamos la recta por un polinomio de grado 9. Con diez puntos, pasa por los diez.



...y No Sirve



Dos Errores

Estimamos $\hat{f}$ con la muestra $\{(x_i, y_i)\}_{i=1}^n$. Hay dos maneras de preguntarle cómo le fue:

El Contrato de la Predicción

La fila predictiva de la tabla exigía: “*que los datos nuevos vengan del mismo proceso*”. Eso es un **supuesto**, no un teorema:

- ▶ Los carros de otra ciudad, otra década u otra plataforma son *otro* proceso.
- ▶ El ejemplo clásico: Google Flu Trends predijo la gripe mejor que el CDC... hasta que el comportamiento de búsqueda cambió y el modelo no se enteró.

Descriptiva: se reporta. Causal: se defiende con diseño.


Predictiva: se defiende **midiendo** Err, y eso exige datos que el modelo no vio.

Agenda

- 1 Repaso: Tres Lecturas Posibles
- 2 El Objeto de Estimación Predictivo
- 3 La Regresión Lineal Aproxima la CEF
- 4 Predecir
- 5 Intuición: Sesgo y Varianza
- 6 Cierre


Intuición: Sesgo y Varianza

Cada tiro es la estimación que sale de **una muestra distinta**:



Intuición: Sesgo y Varianza para funciones

Treinta muestras de $n = 50$ carros; a cada una le aplicamos la misma receta:




En los extremos del odómetro varias curvas del grado 9 se salen del cuadro.

Rígido: se equivoca **parecido** en todas las muestras: varianza baja.

Flexible: acierta **en promedio**, pero varía mucho: varianza alta.

Complejidad Óptima



Agenda


- 1 Repaso: Tres Lecturas Posibles
- 2 El Objeto de Estimación Predictivo
- 3 La Regresión Lineal Aproxima la CEF
- 4 Predecir
- 5 Intuición: Sesgo y Varianza
- 6 Cierre**

Lo Que Viene

- ▶ **Lunes 24/08 (teoría), VIRTUAL.** La descomposición formal y la medición del error fuera de muestra.
- ▶ **Miércoles 26/08 (laboratorio, en R).** Con Julián.

Quedó definido el objeto ($f^* = \mathbb{E}[Y|X]$), el estimador (la familia lineal) y el examen (Err).

Apéndice: Otras Pérdidas, Otros Predictores



Cada pérdida define su propio “mejor predictor”:

- ▶ Cuadrática $\rightarrow$ media condicional $\mathbb{E}[Y|X]$
- ▶ Absoluta $\rightarrow$ mediana condicional
- ▶ Asimétrica $\rightarrow$ un cuantil condicional

Para un concesionario, subvaluar un carro no cuesta lo mismo que sobrevaluarlo: su pérdida es asimétrica, y su mejor predictor no es la media.