

Generalización y el Tradeoff Sesgo-Varianza

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

- 1 Anteriormente ...
- 2 Generalización
 - Sobreajuste y Subajuste
 - Estimación del Error Fuera de Muestra
- 3 Cierre

Planteamiento

- Observamos (Y, X)
- Elegimos un predictor $f : \mathcal{X} \rightarrow \mathbb{R}$ que minimice la pérdida esperada.

$$f^*(X) = \operatorname{argmin}_f \mathbb{E}[(Y - f(X))^2]. \quad (1)$$

Modelo lineal

$$f(X) = Xb \quad (2)$$

Agenda

- 1 Anteriormente ...
- 2 Generalización
 - Sobreajuste y Subajuste
 - Estimación del Error Fuera de Muestra
- 3 Cierre

Generalización

Panorama

- ▶ En ML nos importa la predicción fuera de muestra
- ▶ La generalización se refiere al desempeño de un modelo en datos no vistos.

Generalización

- ▶ A los datos no vistos se les suele llamar **test data**,
- ▶ Mientras que a los datos de la muestra se les llama **training data**.
- ▶ Objetivo:

$$f^*(X) = \operatorname{argmin}_f \mathbb{E}[(Y - f(X))^2]. \quad (3)$$

Generalización

Datos de entrenamiento




Figure 1: Datos de entrenamiento

Generalización

El mismo DGP, fuera de muestra





Figure 2: Datos de prueba (no vistos)


Generalización

Un ajuste




Generalización

Desempeño fuera de muestra




(a) Datos de entrenamiento



(b) Datos de prueba


Generalización

Desempeño fuera de muestra. ¿Más datos?




Generalización

Desempeño fuera de muestra. ¿Datos sin ruido?




Generalización

Modelo más complejo




Generalización

Modelo más complejo. Desempeño fuera de muestra




(a) Datos de entrenamiento



(b) Datos de prueba


Generalización

Modelo más complejo. Desempeño fuera de muestra: más datos




Generalización

Modelo más complejo. Desempeño fuera de muestra: varianza




(a) Datos de entrenamiento 2



(b) Datos de entrenamiento 3


Generalización

Sobreajuste y Subajuste. Tradeoff Sesgo-Varianza




Generalización

Sobreaajuste y Subajuste. Tradeoff Sesgo-Varianza



Descomposición matemática para regresión

Tradeoff Sesgo-Varianza



Fuente: <https://tinyurl.com/y4lvjxpc>

- El secreto mejor guardado del ML: tolerando algo de sesgo podemos tener ganancias importantes en varianza

Generalización

Ideas clave del Tradeoff Sesgo-Varianza

- ▶ El término de sesgo refleja el error que introduce la incapacidad del modelo de aproximar la función verdadera f^* .
- ▶ El término de varianza refleja la sensibilidad del modelo al training set específico.
- ▶ A medida que crece el tamaño de la muestra, la varianza en general disminuye.
- ▶ El término de ruido σ^2 es inevitable y no se puede predecir.
- ▶ La descomposición para problemas de clasificación es menos clara que para problemas de regresión, pero sigue presente.

Generalización

Train y Test Sets. Predicción dentro y fuera de muestra.

- ▶ ¿Cómo seleccionamos la parametrización que minimice el error de predicción fuera de muestra?
- ▶ Problema: solo contamos con una muestra

Dos errores

- ▶ Dentro de muestra, el que podemos calcular:

$$\text{err}_{\text{ent}} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{f}(x_i))^2$$

- ▶ Fuera de muestra, el que nos importa:

$$\text{Err} = \mathbb{E}[(Y^0 - \hat{f}(X^0))^2]$$

- ▶ Uno es un promedio sobre los datos que tenemos. El otro es una esperanza sobre datos que no tenemos

Error de entrenamiento

- ▶ ¿Sirve err_{ent} para estimar Err ?
- ▶ No. Y no falla al azar: subestima sistemáticamente
- ▶ $\hat{f}$ se eligió minimizando el error en esos mismos puntos
- ▶ Al hacerlo absorbió el ϵ_i de cada observación
- ▶ $R^2 = 1$ y $\text{err}_{\text{ent}} = 0$ son el síntoma, no la virtud

Error de generalización


- ▶ Para seleccionar la mejor parametrización con respecto a Err , es necesario estimarlo.
- ▶ Hay dos enfoques comunes:
 - ▶ Podemos estimar indirectamente el error de la prueba haciendo un ajuste al error de entrenamiento para tener en cuenta el sesgo debido al sobreajuste $\Rightarrow$ Penalización ex post: AIC , BIC , MSE_{adj} , R^2_{adj} , etc.

Usar la misma muestra y estimar directamente Err

- ▶ Err es una esperanza sobre datos que no tenemos
- ▶ Y solo contamos con una muestra
- ▶ La salida: usar esa misma muestra para fabricar datos nuevos.
 - ▶ Levantarnos tirando de nuestros propios *bootstraps*

Partición de la muestra

- ▶ No tenemos datos del futuro
- ▶ Apartamos parte de la muestra y no la dejamos participar en el entrenamiento



- ▶ El promedio sobre validación estima Err sin optimismo: esos carros no participaron en la elección de $\hat{f}$

Agenda

- 1 Anteriormente ...
- 2 Generalización
 - Sobreajuste y Subajuste
 - Estimación del Error Fuera de Muestra
- 3 Cierre

Recap

- ▶ Nos importa Err , el error en datos que el modelo no vio
- ▶ Más complejidad baja err_{ent} siempre; a Err no
- ▶ El error se descompone en sesgo, varianza y ruido
- ▶ Tolerando algo de sesgo se puede ganar mucho en varianza
- ▶ err_{ent} no sirve para estimar Err : subestima
- ▶ Err se estima apartando datos, no mirando el ajuste

Próximas clases

- ▶ Miércoles 26/08: laboratorio en R, con Julián, llevar esto a los datos
- ▶ Lunes 31/08: teoría + sobre esto
- ▶ Miércoles 02/09: en R