

Selección de Modelos y Regularización

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri


Universidad de los Andes

August 27, 2025


Agenda

- 1 Recap: Predicción y Overfit
- 2 Selección de Modelos
- 3 Regularización
 - Lasso

Overfit y Predicción fuera de Muestra



Overfit y Predicción fuera de Muestra



Overfit y Predicción fuera de Muestra

- ML nos interesa la predicción fuera de muestra

Overfit y Predicción fuera de Muestra

- ▶ ML nos interesa la predicción fuera de muestra
- ▶ Overfit: modelos complejos predicen muy bien dentro de muestra, pero tienden a hacer un mal trabajo fuera de muestra
- ▶ Hay que elegir el modelo que “mejor” prediga
 - ▶ Métodos de Remuestreo
 - ▶ Enfoque del conjunto de validación
 - ▶ Loocv
 - ▶ Validación cruzada en K-partes (5 o 10)

Selección de Modelos: Motivación

- ▶ Tenemos M_k modelos
- ▶ Queremos encontrar el que mejor predice fuera de muestra
- ▶ Hay distintas formas de enfrentarlo
- ▶ Las clásicas
 - ▶ Elección del mejor conjunto
 - ▶ Elección por pasos
 - ▶ Hacia adelante (Forward selection)
 - ▶ Hacia atrás (Backward selection)

Regularización

Lasso

- Para un $\lambda \geq 0$ dado, consideremos el siguiente problema de optimización

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p |\beta_j| \quad (1)$$

Lasso

- ▶ Para un $\lambda \geq 0$ dado, consideremos el siguiente problema de optimización

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p |\beta_j| \quad (1)$$

- ▶ “LASSO’s free lunch”: selecciona automáticamente los predictores que van en el modelo ($\beta_j \neq 0$) y los que no ($\beta_j = 0$)
- ▶ Por qué? Los coeficientes que no van son soluciones de esquina
- ▶ $L(\beta)$ es no differentiable

Lasso Intuición en 1 Dimension

- Lasso Intuición

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2 + \lambda |\beta| \quad (2)$$


- Un solo predictor, un solo coeficiente

- Si $\lambda = 0$


$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_i \beta)^2 \quad (3)$$

- la solución es?


Intuición en 1 Dimension




Intuición en 1 Dimension




Intuición en 1 Dimension




Intuición en 1 Dimension




Intuición en 1 Dimension




Intuición en 1 Dimension



Intuición en 1 Dimension




Intuición en 1 Dimensión



Intuición en 2 Dimensiones (OLS)


$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \quad (4)$$



Fuente: <https://allmodelsarewrong.github.io>


Intuición en 2 Dimensiones (Lasso)

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } (|\beta_1| + |\beta_2|) \leq c \quad (5)$$



Intuición en 2 Dimensiones (Lasso)

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a } (|\beta_1| + |\beta_2|) \leq c \quad (6)$$



Comentarios técnicos

- ▶ Importante para aplicación:
 - ▶ Estandarizar los datos (media 0, y varianza 1)
 - ▶ Como elegimos λ ?

Comentarios técnicos: selección de λ

- ▶ Como elegimos λ ?
- ▶ λ es un parámetro y lo elegimos usando validación cruzada
 - 1 Partimos la muestra de entrenamiento en K Partes: $M_{train} = M_{fold 1} \cup M_{fold 2} \cdots \cup M_{fold K}$
 - 2 Cada conjunto $M_{fold K}$ va a jugar el rol de una muestra de evaluación $M_{eval k}$. Entonces para cada muestra
 - ▶ $M_{train-1} = M_{train} - M_{fold 1}$
 - ▶ \vdots
 - ▶ $M_{train-k} = M_{train} - M_{fold k}$
 - 3 Luego hacemos el siguiente loop
 - 1 Para $\lambda_i = 0, 0.001, 0.002, \dots, \lambda_{max}$
 - Para $k = 1, \dots, K$
 - Ajustar el modelo $m_{i,k}$ con λ_i en $M_{train-k}$
 - Calcular y guardar el $MSE(m_{i,k})$ usando M_{eval-k}
 - fin para k
 - Calcular y guardar $MSE_i = \frac{1}{K} MSE(m_{i,k})$
 - 2 fin para λ
 - 4 Encontrar el menor MSE_i y usar ese $\lambda_i = \lambda^*$