

Validación Cruzada y Selección de Modelos Lineales

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda


- 1 La Descomposición del Error
- 2 Medir Err
- 3 Validación Cruzada
 - LOOCV
 - Validación Cruzada en K Partes
- 4 Selección de Modelos Lineales
 - Elección del Mejor Conjunto
 - Elección por Pasos
- 5 Cierre

Dos errores


- ▶ Dentro de muestra
- ▶ Fuera de muestra

Tradeoff

Sesgo



Varianza



Tradeoff Sesgo Varianza

Agenda

- 1 La Descomposición del Error
- 2 Medir Err**
- 3 Validación Cruzada
 - LOOCV
 - Validación Cruzada en K Partes
- 4 Selección de Modelos Lineales
 - Elección del Mejor Conjunto
 - Elección por Pasos
- 5 Cierre

El problema de medición

$\text{Err}(x_0)$ promedia sobre dos cosas que no tenemos:

- ▶ la **observación no vista**; todavía no llegó;
- ▶ la **repetición del muestreo**; tenemos una muestra, y una sola.

Y f^* , que aparece en el sesgo, es justamente lo que no conocemos.

La descomposición explica **por qué** existe la U.
No sirve para encontrar su mínimo con datos.

Por qué err_{ent} miente

Tenemos un número a la mano: el error de entrenamiento. ¿Sirve como estimación de Err?

No, y lo importante es **cómo** falla: no se equivoca al azar, se equivoca siempre **hacia abajo**.

- ▶ $\hat{f}$ se eligió para minimizar el error *en esos mismos puntos*;
- ▶ al hacerlo absorbió el ϵ_i de cada observación, que en el dato nuevo va a ser otro.

$$R^2 = 1 \text{ y error de entrenamiento} = 0$$

Error de generalización

- ▶ Para seleccionar el mejor modelo con respecto a Err , es necesario estimarlo.
- ▶ Hay dos enfoques comunes:
 - ▶ Podemos estimar indirectamente el error de la prueba haciendo un ajuste al error de entrenamiento para tener en cuenta el sesgo debido al sobreajuste $\Rightarrow$ Penalización ex post: AIC, BIC, MSE_{adj} , R^2_{adj} , etc.

Error de generalización


- ▶ Para seleccionar el mejor modelo con respecto a Err, es necesario estimarlo.
- ▶ Hay dos enfoques comunes:
 - ▶ Podemos estimar indirectamente el error de la prueba haciendo un ajuste al error de entrenamiento para tener en cuenta el sesgo debido al sobreajuste $\Rightarrow$ Penalización ex post: AIC, BIC, MSE_{adj} , R^2_{adj} , etc.
 - ▶ Usar la misma muestra y estimar directamente Err

Usar la misma muestra y estimar directamente Err


- ▶ Err es una esperanza sobre datos que no tenemos
- ▶ Y solo contamos con una muestra
- ▶ La salida: usar esa misma muestra para fabricar datos nuevos.
 - ▶ Levantarnos tirando de nuestros propios *bootstraps*

Partición de la muestra

- ▶ No tenemos datos del futuro
- ▶ Apartamos parte de la muestra y no la dejamos participar en el entrenamiento



La partición, vista en los datos




- La partición aleatoriza **filas**. Ninguna columna se toca
- El promedio sobre validación estima Err sin optimismo: esas observaciones no participaron en la elección de $\hat{f}$

Agenda


- 1 La Descomposición del Error
- 2 Medir Err
- 3 Validación Cruzada
 - LOOCV
 - Validación Cruzada en K Partes
- 4 Selección de Modelos Lineales
 - Elección del Mejor Conjunto
 - Elección por Pasos
- 5 Cierre

La aleatorización importa



100 particiones 70/30 de los mismos 300 carros, polinomio de grado 5.

No cambia solo el número: cambia la decisión




Diez aleatorizaciones por panel; los puntos rojos marcan el grado ganador de cada una.

Los dos precios de una sola partición

1. **Se entrena con menos datos.** $\hat{f}$ sale de 210 carros y no de 300: el número mide un modelo peor que el que vamos a usar
2. **Depende de la aleatorización.** La estimación tiene varianza propia

¿Y si en vez de aleatorizar una vez lo hacemos muchas y promediamos?

Leave-One-Out Cross Validation



Validación cruzada en K partes

y	x_1	x_2	x_3	y	x_1	x_2	x_3	y	x_1	x_2	x_3	y	x_1	x_2	x_3	y	x_1	x_2	x_3

MSE_1

MSE_2

MSE_3

MSE_4

MSE_5

Las tres estimaciones, sobre el mismo eje



100 repeticiones de cada método. LOOCV es un punto: no aleatoriza.

¿Por qué 5 o 10 y no n ?

- ▶ **Sesgo:** una sola partición entrena con menos datos y *sobreestima* Err **en promedio**. LOOCV entrena con $n - 1$: casi sin sesgo. K -fold queda en el medio
- ▶ **Varianza:** LOOCV promedia n modelos entrenados sobre bases casi idénticas $\Rightarrow$ muy correlacionados, y el promedio de cosas correlacionadas no baja mucho la varianza
- ▶ Con K -fold los K modelos se parecen menos entre sí

$K = 5$ o $K = 10$: ni el sesgo de una partición ni la varianza de LOOCV.


Agenda

- 1 La Descomposición del Error
- 2 Medir Err
- 3 Validación Cruzada
 - LOOCV
 - Validación Cruzada en K Partes
- 4 Selección de Modelos Lineales
 - Elección del Mejor Conjunto
 - Elección por Pasos
- 5 Cierre

Selección de modelos lineales: motivación

- ▶ Tenemos M_k modelos lineales
- ▶ Queremos encontrar el que mejor predice fuera de muestra
- ▶ Hay distintas formas de enfrentarlo
- ▶ Las clásicas
 - ▶ Elección del mejor conjunto
 - ▶ Elección por pasos
 - ▶ Hacia adelante (*forward*)
 - ▶ Hacia atrás (*backward*)

Un modelo es un subconjunto de columnas



► La validación cruzada partía **filas**. Acá elegimos **columnas**

Elección del mejor conjunto

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + u$$

- 1 Estimar *todos* los modelos posibles con $k = 0, 1, \dots, p$ predictores
- 2 Calcular el error de predicción de cada uno con validación cruzada
- 3 Quedarse con el de menor error de predicción

Elección del mejor conjunto

Un algoritmo factible

- 1 Sea M_0 el modelo nulo, sin predictores: predice la media muestral
- 2 Para $k = 1, 2, \dots, p$:
 - 1 Ajustar los $\binom{p}{k}$ modelos con exactamente k predictores
 - 2 Quedarse con el mejor de esos $\binom{p}{k}$ y llamarlo M_k (mejor = menor SSR)
- 3 Elegir uno solo entre $M_0, \dots, M_p$ con **validación cruzada**

Cuántos modelos hay que ajustar

p	Mejor conjunto 2^p
3	8
10	1.024
20	1.048.576
40	1.099.511.627.776

Elección por pasos

- ▶ Por cómputo, la elección del mejor conjunto no se puede aplicar con p grande
- ▶ Con p grande también aparecen problemas estadísticos
- ▶ Un espacio de búsqueda enorme lleva a sobreajuste y a coeficientes de varianza alta
- ▶ Por las dos razones, los métodos por pasos, que exploran un conjunto de modelos mucho más restringido, son una alternativa interesante

Elección por pasos

Los dos algoritmos


1 **Hacia adelante** (*forward*)

- ▶ Empezar sin predictores
- ▶ Probar todos los modelos con 1 predictor y quedarse con el mejor
- ▶ Agregar de a un predictor por vez, sin sacar ninguno
- ▶ De los $p + 1$ modelos, elegir el de menor error de predicción con validación cruzada

2 **Hacia atrás** (*backward*)

- ▶ La misma idea, pero arrancando del modelo completo y sacando de a uno


Hacia adelante: el camino sobre el mapa



★ el mejor par de los tres. *Forward* nunca lo ajusta.

► Una vez que entra x_3 , el par $\{x_1, x_2\}$ es **inalcanzable**

Hacia atrás



★ el mismo par de la slide anterior.

- Acá sí pasa por $\{x_1, x_2\}$: desde el modelo completo mira los tres pares
- Con $p = 4$, ¿sigue pasando?

Cuántos modelos hay que ajustar

p	Mejor conjunto 2^p	Por pasos $1 + p(p + 1)/2$
3	8	7
10	1.024	56
20	1.048.576	211
40	1.099.511.627.776	821

Por pasos: qué se gana y qué se pierde

- ▶ Se pasa de 2^p modelos a $1 + p(p + 1)/2$
- ▶ Ninguno de los dos garantiza encontrar el mejor de los 2^p
- ▶ *Forward*: una columna que entró, no sale
- ▶ *Backward*: una columna que salió, no vuelve. Y exige $n > p$ para poder ajustar el modelo completo
- ▶ *Forward* corre con $n < p$
- ▶ El anidamiento es lo que los hace “factibles”, y es lo que los hace fallar

Agenda

- 1 La Descomposición del Error
- 2 Medir Err
- 3 Validación Cruzada
 - LOOCV
 - Validación Cruzada en K Partes
- 4 Selección de Modelos Lineales
 - Elección del Mejor Conjunto
 - Elección por Pasos
- 5 Cierre

Recap

- ▶ Err se descompone en tres: ruido irreducible, sesgo² y varianza
- ▶ Err se estima apartando datos, no mirando el ajuste dentro de la muestra
- ▶ Con **una** partición, la estimación depende de la partición, lo que afecta la decisión
- ▶ **LOOCV** no aleatoriza: deja una fila afuera n veces y promedia
- ▶ **K-fold** con $K = 10$ llega prácticamente al mismo número, mucho más barato
- ▶ Elegir modelo es elegir **columnas**: hay 2^p candidatos
- ▶ *Forward* y *backward* son “baratos” porque anidan, y fallan por lo mismo

Próximas clases

- ▶ Miércoles 02/09: laboratorio en R, pondremos al agente a trabajar sobre esto
- ▶ Domingo 06/09: vence el examen (Respondus y LockDown Browser)