

Lasso

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

- 1 Recap: Selección de Modelos Lineales
 - Elección del Mejor Conjunto

- 2 Lasso

Selección de modelos lineales: motivación


- ▶ Tenemos M_k modelos lineales
- ▶ Queremos encontrar el que mejor predice fuera de muestra
- ▶ Hay distintas formas de enfrentarlo
- ▶ Las clásicas
 - ▶ Elección del mejor conjunto
 - ▶ Elección por pasos
 - ▶ Hacia adelante (*forward*)
 - ▶ Hacia atrás (*backward*)

Elección del mejor conjunto

$$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p + u$$

- 1 Estimar *todos* los modelos posibles con $k = 0, 1, \dots, p$ predictores
- 2 Quedarse con el de menor error de predicción


Hacia adelante



★ el mejor par de los tres. *Forward* nunca lo ajusta.

► Una vez que entra x_3 , el par $\{x_1, x_2\}$ es **inalcanzable**

Hacia atrás



★ el mismo par de la lámina anterior.

- Acá sí pasa por $\{x_1, x_2\}$: desde el modelo completo mira los tres pares

Cuántos modelos hay que ajustar

p	Mejor conjunto 2^p	Por pasos $1 + p(p + 1)/2$
3	8	7
10	1.024	56
20	1.048.576	211
40	1.099.511.627.776	821

De la selección discreta al shrinkage

- ▶ Best subset equivale a penalizar el *número* de predictores:

$$\min_{\beta} \sum_{i=1}^n (y_i - x_i' \beta)^2 + \lambda \|\beta\|_0, \quad \|\beta\|_0 = \#\{j : \beta_j \neq 0\}$$

- ▶ Dos problemas:
 - ▶ **Computacional:** $\|\beta\|_0$ no es convexa $\Rightarrow$ hay que buscar sobre los 2^p subconjuntos
 - ▶ **Estadístico:** la selección es discreta (un predictor está o no está); pequeños cambios en los datos cambian el subconjunto elegido $\Rightarrow$ alta varianza
- ▶ **Idea:** reemplazar $\|\beta\|_0$ por una penalización continua que *encoja* los coeficientes en vez de eliminarlos de golpe

Agenda

- 1 Recap: Selección de Modelos Lineales
 - Elección del Mejor Conjunto

- 2 Lasso

Lasso

- Para un $\lambda \geq 0$ dado, consideremos el siguiente problema de optimización

$$\min_{\beta} E(\beta) = \underbrace{\sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2}_{\text{SSR}(\beta)} + \lambda \sum_{j=1}^p |\beta_j| \quad (1)$$

Lasso

- Para un $\lambda \geq 0$ dado, consideremos el siguiente problema de optimización

$$\min_{\beta} E(\beta) = \underbrace{\sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2}_{\text{SSR}(\beta)} + \lambda \sum_{j=1}^p |\beta_j| \quad (1)$$

- “LASSO’s free lunch”: selecciona automáticamente los predictores que van en el modelo ($\beta_j \neq 0$) y los que no ($\beta_j = 0$)
- ¿Por qué? Los coeficientes que no van son soluciones de esquina
- $E(\beta)$ es no diferenciable: la penalidad $\lambda \sum_{j=1}^p |\beta_j|$ tiene un quiebre en cero

Lasso Intuición en 1 Dimensión

► Lasso Intuición

$$\min_{\beta} E(\beta) = \underbrace{\sum_{i=1}^n (\tilde{y}_i - \tilde{x}_i \beta)^2}_{\text{SSR}(\beta)} + \lambda |\beta| \quad (2)$$

► Un solo predictor, un solo coeficiente, **las dos** variables normalizadas


$$\tilde{x}_i = \frac{x_i - \bar{x}}{\sqrt{\sum_{j=1}^n (x_j - \bar{x})^2}}, \quad \tilde{y}_i = \frac{y_i - \bar{y}}{\sqrt{\sum_{j=1}^n (y_j - \bar{y})^2}}$$

Intuición en 1 Dimensión


- Si $\lambda = 0$

$$\min_{\beta} \sum_{i=1}^n (\tilde{y}_i - \tilde{x}_i \beta)^2 \quad (3)$$

- ¿La solución es?




Intuición en 1 Dimensión




Intuición en 1 Dimensión

Las dos piezas por separado




Intuición en 1 Dimensión

Las dos piezas por separado




Intuición en 1 Dimensión


Las dos piezas por separado




Intuición en 1 Dimensión




Intuición en 1 Dimensión




Intuición en 1 Dimensión




Intuición en 1 Dimensión



Intuición en 1 Dimensión




Intuición en 1 Dimensión



Intuición en 2 Dimensiones (MCO)


$$\min_{\beta} \text{SSR}(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \quad (4)$$



Fuente: <https://allmodelsarewrong.github.io>


Intuición en 2 Dimensiones (Lasso)

$$\min_{\beta} \text{SSR}(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } (|\beta_1| + |\beta_2|) \leq c \quad (5)$$



Intuición en 2 Dimensiones (Lasso)

$$\min_{\beta} \text{SSR}(\beta) = \sum_{i=1}^n (y_i - x_{i1}\beta_1 - x_{i2}\beta_2)^2 \text{ s.a. } (|\beta_1| + |\beta_2|) \leq c \quad (6)$$



Comentarios técnicos

- ▶ Importante para aplicación:
 - ▶ Estandarizar los datos (media 0 y varianza 1)
 - ▶ ¿Cómo elegimos λ ?

Selección de λ

- ▶ Asegurar cero sesgo dentro de muestra crea problemas fuera de muestra: trade-off Sesgo-Varianza
- ▶ El lasso hace este trade-off de forma empírica.

$$\min_{\beta} E(\beta) = \sum_{i=1}^n (y_i - \beta_0 - x_{i1}\beta_1 - \cdots - x_{ip}\beta_p)^2 + \lambda \sum_{j=1}^p |\beta_j|$$

- ▶ λ es el precio al que hacemos este trade-off
- ▶ ¿Cómo elegimos λ ?

Selección de λ (K-fold CV)

- ▶ Primero separamos la muestra en **entrenamiento** y **prueba** (*test*). El test se guarda y no se toca hasta la evaluación final
- ▶ λ es un hiperparámetro: lo elegimos por validación cruzada *dentro* de la muestra de entrenamiento
- ▶ Partimos la muestra de entrenamiento en K folds de tamaño similar (en la práctica, $K = 5$ o 10)
- ▶ Cada fold $k = 1, \dots, K$ juega una vez el rol de muestra de validación:
 - ▶ entrenamos con los otros $K - 1$ folds
 - ▶ evaluamos en el fold k
- ▶ Así, cada observación se usa para entrenar y (una sola vez) para validar

Selección de λ (Algoritmo)

- ▶ Para cada λ en una grilla $\{\lambda_1, \dots, \lambda_L\}$ y cada fold $k = 1, \dots, K$:
 - ▶ Ajustar lasso *sin* el fold $k \rightarrow \hat{\beta}_{-k}(\lambda)$
 - ▶ Evaluar en las n_k observaciones del fold k (no usadas para entrenar):

$$\text{MSE}_k(\lambda) = \frac{1}{n_k} \sum_{i \in \text{fold } k} (y_i - x_i' \hat{\beta}_{-k}(\lambda))^2$$

- ▶ Promediar sobre los folds y elegir el mejor λ :

$$\text{CV}(\lambda) = \frac{1}{K} \sum_{k=1}^K \text{MSE}_k(\lambda), \quad \lambda^* = \arg \min_{\lambda} \text{CV}(\lambda)$$

- ▶ Con λ^* elegido, reestimamos $\hat{\beta}_{\text{lasso}}(\lambda^*)$ con *toda* la muestra de entrenamiento
- ▶ Recién ahí evaluamos, **una sola vez**, en la muestra de prueba

Para cerrar

- ▶ **El lasso selecciona.** La penalidad ℓ_1 no encoge y ya: en las esquinas de la región factible manda coeficientes a **cero exacto**. El modelo sale de la estimación, no de una decisión previa nuestra
- ▶ Y lo hace porque el problema es una **optimización restringida**: el cero es una *solución de esquina*, con su desigualdad de Kuhn-Tucker
- ▶ **Pero λ no lo elige el lasso.** Es un hiperparámetro nuestro, y fija todo lo demás:
 - ▶ $\lambda = 0 \Rightarrow$ MCO, ninguna selección
 - ▶ λ grande $\Rightarrow$ todos los coeficientes en cero
- ▶ λ **se elige por validación cruzada**, con el mismo aparato del bloque anterior: una grilla de λ , K folds, y el que minimiza el error estimado
- ▶ El miércoles lo vemos en R.