

Árboles de regresión (CART)

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Motivación

- Queremos predecir:


$$\text{Precio} = f(\text{atributos estructurales, amenidades, } \dots) \quad (1)$$

- Podemos aplicar regresión lineal,

$$\text{Precio} = \beta_0 + \beta_1 \text{ Habitaciones} + \beta_2 \text{ DCBD} + u \quad (2)$$

- Aplicar MCO a este problema requiere tomar algunas decisiones: qué variables, qué forma funcional, qué interacciones.
- Los árboles toman esas decisiones *desde los datos*.

Motivación




Agenda

- 1 ¿Qué hacen?
- 2 ¿Cómo lo hacen?
- 3 Sobreajuste


¿Qué hacen?

“Recursive binary splitting”




¿Qué hacen?

“Recursive binary splitting”




¿Qué hacen?

“Recursive binary splitting”





¿Qué hacen?

“Recursive binary splitting”



En cada región R_m la predicción es la media: $\hat{y} = \bar{y}_{R_m}$.

¿Qué hacen?



Agenda

- 1 ¿Qué hacen?
- 2 ¿Cómo lo hacen?
- 3 Sobreajuste

¿Cómo construimos un árbol de regresión?

- ▶ Datos: $y_{n \times 1}$ y $X_{n \times k}$
- ▶ Definiciones
 - ▶ j es la variable que parte el espacio y s es el punto de partición
 - ▶ Defina los siguientes semiplanos

$$R_1(j, s) = \{X \mid X_j \leq s\} \ \& \ R_2(j, s) = \{X \mid X_j > s\} \quad (3)$$

- ▶ El problema: usando una “pérdida cuadrática”, buscar la variable de partición X_j y el punto s de forma tal que:

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right] \quad (4)$$

¿Cómo construimos un árbol de regresión?




photo from <https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/>

Agenda

- 1 ¿Qué hacen?
- 2 ¿Cómo lo hacen?
- 3 Sobreajuste

Sobreajuste



Sobreajuste. Algunas soluciones

- ▶ Fijar la profundidad del árbol.
- ▶ Fijar la mínima cantidad de datos que están contenidos dentro de cada hoja.
- ▶ Pruning (poda).
 - ▶ Dejar crecer un árbol muy grande T_0
 - ▶ Luego cortarlo obteniendo un sub-árbol (*subtree*)
 - ▶ ¿Cómo cortarlo?

Pruning (poda)

- ▶ No es posible calcular el error de predicción usando cross-validation para cada sub-árbol posible
- ▶ Solución: *Cost complexity pruning* (cortar las ramas más débiles)
 - ▶ Indexamos los árboles con T .
 - ▶ Un sub-árbol $T \subset T_0$ es un árbol que se obtuvo colapsando nodos internos de T_0 (cortando ramas).
 - ▶ $|T|$ = número de nodos terminales (hojas) del árbol T

Pruning (poda)

- Cost complexity del árbol T

$$C_\alpha(T) = \sum_{m=1}^{|T|} n_m Q_m(T) + \alpha |T| \quad (5)$$

- donde $Q_m(T) = \frac{1}{n_m} \sum_{x_i \in R_m} (y_i - \hat{y}_m)^2$ para los árboles de regresión, así que $\sum_m n_m Q_m(T)$ es la SSR del árbol
- $Q_m(T)$ penaliza la heterogeneidad dentro de la región y α el número de regiones
- Objetivo: para un α dado, encontrar el sub-árbol T_α que minimice $C_\alpha(T)$

Pruning (poda)

- Mecanismo de búsqueda para T_α (pruning óptimo dado α).

Resultado: para cada α hay un sub-árbol único T_α que minimiza $C_\alpha(T)$.

- Eliminar sucesivamente las ramas que producen un aumento mínimo en $\sum_{m=1}^{|T|} n_m Q_m(T)$
- Se colapsa hasta el nodo inicial pero va a través de una sucesión de árboles $T_0 \supset T_1 \supset \dots \supset \{\text{raíz}\}$
- T_α pertenece a esta secuencia. (Breiman et al., 1984)

Pruning (poda)

Algoritmo completo

- 1 Utilizamos particiones recursivas binarias para hacer crecer el árbol T_0
- 2 Aplicamos *cost complexity pruning* a T_0 para obtener la secuencia de sub-árboles como función de α .
- 3 Utilizamos K-fold cross-validation para elegir α .
- 4 Tenemos entonces una secuencia de sub-árboles para distintos valores de α
- 5 Elegimos el α y el sub-árbol que tienen el menor error de predicción.

Ejemplo



photo from <https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/>