

Tree-Based Methods

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

1 Recap

2 Motivación

- Árboles
- Bagging
- Random Forests

Agenda

1 Recap

2 Motivación

- Árboles
- Bagging
- Random Forests

Motivación

- ▶ El objetivo es predecir fuera de muestra y dadas otras variables X . Ej: ingresos, default, pobreza, etc.
- ▶ Asumimos que el link entre y and X esta dado por el modelo:

$$y = f(X) + u \quad (1)$$

- ▶ Hasta ahora vimos modelos lineales o linealizables.
 - ▶ Regresión lineal, logistica
- ▶ Árboles (CARTs)
 - ▶ Modelo flexible e interpretable para la relación entre y y X .
 - ▶ Para que? No-linealidades, interacciones.


Motivación

► Inspirados por Leo Breiman:

"There are two cultures in the use of statistical modeling to reach conclusions from data. One assumes that the data are generated by a given stochastic data model. The other uses algorithmic models and treats the data mechanism as unknown." Breiman [2001b], p199.

"The statistical community has been committed to the almost exclusive use of data models. This commitment has led to irrelevant theory, questionable conclusions, and has kept statisticians from working on a large range of interesting current problems. Algorithmic modeling, both in theory and practice, has developed rapidly in fields outside statistics. It can be used both on large complex data sets and as a more accurate and informative alternative to data modeling on smaller data sets. If our goal as a field is to use data to solve problems, then we need to move away from exclusive dependence on data models and adopt a more diverse set of tools." Breiman [2001b], p199.

Motivación



Ventajas y Desventajas de los Árboles

► Pros:


- Los árboles son muy fáciles de explicar a las personas (probablemente incluso más fáciles que la regresión lineal)
- Los árboles se pueden trazar gráficamente y son fácilmente interpretados incluso por no expertos. Variables más importantes en la parte superior
- Funcionan bien en problemas de clasificación y regresión.

► Cons:

- Los árboles no son muy precisos o robustos (ensamblados, bosques aleatorios y boosting al rescate)
- Si la estructura es lineal, CART no funciona bien

Árboles vs. Modelos Lineales

- ▶ Cuál modelo es mejor?
 - ▶ Si la relación entre los predictores y la respuesta es lineal, los modelos lineales clásicos, como la regresión lineal, superan a los árboles de regresión.
 - ▶ Por otro lado, si la relación entre los predictores no es lineal, los árboles de decisión superarían a los enfoques clásicos.
- ▶ Arriba: el límite es lineal
 - ▶ Izquierda: modelo lineal (bueno)
 - ▶ Derecha: árbol
- ▶ Abajo: el límite es no-lineal
 - ▶ Izquierda: linear model
 - ▶ Derecha: arbol (good)



Bagging


- ▶ Problema con CART: pocos robustos.
- ▶ Idea: podemos mejorar mucho el rendimiento mediante la agregación

Bagging

- ▶ Bagging:

- ▶ Obtenga muestras aleatorias $(X_i^b, Y_i^b)_{i=1}^N$ de la muestra observada (bootstrap).

Bagging



Bagging

- ▶ Bagging:
 - ▶ Obtenga muestras aleatorias $(X_i^b, Y_i^b)_{i=1}^N$ de la muestra observada (bootstrap).

Bagging

- Bagging:

- Obtenga muestras aleatorias $(X_i^b, Y_i^b)_{i=1}^N$ de la muestra observada (bootstrap).
- Para cada muestra, ajuste un árbol de regresión $\hat{f}^b(x)$
- Promedie las muestras de bootstrap



$$\hat{f}_{bag} = \frac{1}{B} \sum_{b=1}^B \hat{f}^b(x) \quad (2)$$

Bagging

- ▶ Bagging:
 - ▶ Obtenga muestras aleatorias $(X_i^b, Y_i^b)_{i=1}^N$ de la muestra observada (bootstrap).
 - ▶ Para cada muestra, ajuste un árbol de regresión $\hat{f}^b(x)$
 - ▶ Promedie las muestras de bootstrap

$$\hat{f}_{bag} = \frac{1}{B} \sum_{b=1}^B \hat{f}^b(x) \quad (2)$$

Bagging



$f(\text{boy}) = (2000 + 900)/2 = 1450$ $f(\text{man}) = (1000 + 450)/2 = 725$

Ejemplo



photo from <https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/>

Bagging

Out-of-Bag Error: Intuición

- ▶ En Bagging, entrenamos múltiples modelos sobre muestras bootstrap.
- ▶ Cada muestra contiene $\sim 63\%$ de los datos originales.
- ▶ Estas muestras no usadas se llaman Out-of-Bag (OOB).

Bagging

Out-of-Bag Error: Matemáticamente

Sean:

- ▶ $\{(x_i, y_i)\}_{i=1}^n$: conjunto de entrenamiento.
- ▶ $T_1, \dots, T_B$: arboles entrenados en cada muestra bootstrap.
- ▶ $\mathcal{B}_i \subset \{1, \dots, B\}$: índices de modelos donde x_i no fue usado (OOB).

Entonces, el error OOB es:

$$E_{OOB} = \frac{1}{n} \sum_{i=1}^n L \left(y_i, \frac{1}{|\mathcal{B}_i|} \sum_{b \in \mathcal{B}_i} T_b(x_i) \right)$$

- ▶ L función de pérdida (error cuadrático, 0 – 1, etc.).
- ▶ Estima el **error de generalización, fuera de muestra** sin necesidad de un set de validación.

Random Forests

- ▶ Problema con el bagging: si hay un predictor fuerte, diferentes árboles son muy similares entre sí.
- ▶ Bosques (forests): reduce la correlación entre los árboles en el bootstrap.
- ▶ Si hay p predictores, en cada partición use solo $m < p$ predictores, elegidos al azar.
- ▶ Bagging es forests con $m = p$ (usando todo los predictores en cada partición).
- ▶ m es un hiper-parámetro, $m = \sqrt{p}$ es un benchmark

Ejemplo



photo from <https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/>

Importancia de Variables por Permutación: Intuición

- ▶ En modelos tipo Random Forests, queremos saber:

¿Qué tan importante es cada variable para las predicciones?

- ▶ La idea:

- ▶ Medimos cuánto empeora el desempeño del modelo si rompemos la relación entre una variable y el objetivo.

- ▶ ¿Cómo rompemos esa relación?

- ▶ Permutando los valores de la variable, dejando las otras igual.

- ▶ Si la variable es importante, el error debería aumentar.

Importancia por Permutación: Definición

- ▶ Sea E_{OOB} : error del modelo usando los datos OOB.
- ▶ Para cada variable j :
 - ▶ Permutamos la columna x_j en los datos OOB.
 - ▶ Calculamos el nuevo error: $E_{\text{perm}(j)}$.
- ▶ La importancia de la variable j es:

$$\text{VI}(j) = E_{\text{perm}(j)} - E_{\text{OOB}}$$

- ▶ Si x_j es irrelevante, el error no debería cambiar.
- ▶ Si x_j es clave, el error aumentará.

Ejemplo



photo from <https://www.dailydot.com/parsec/batman-1966-labels-tumblr-twitter-vine/>