

Árboles Causales

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

- 1 Motivación
- 2 Efectos heterogéneos: ¿para quién funciona?
- 3 ¿Cómo encontrar la heterogeneidad?

McDonald's is reportedly using AI to "dynamically" price its burgers

Algorithms estimate "customer willingness to pay" at each location.

by Lawrence Bonk • Sept. 29, 2026 1:00 pm EST



Motivación

A/B testing de precios

Agenda

- 1 Motivación
- 2 Efectos heterogéneos: ¿para quién funciona?
- 3 ¿Cómo encontrar la heterogeneidad?

Efectos heterogéneos: ¿Para quién funciona?

Grupo	Efecto
Jóvenes	+10
Mayores	-2

El efecto promedio condicional (CATE)

Estimar CATEs

- Regresión lineal con interacciones:

$$Y_i = \alpha + \beta W_i + \gamma X_i + \delta (W_i X_i) + \varepsilon_i$$

- Con W aleatorio:

$$\tau(x) = \beta + \delta x \tag{1}$$

¿Y con muchas X?

- Con 20 covariables:

$$Y_i = \alpha + \beta W_i + X_i' \gamma + W_i X_i' \delta + \varepsilon_i$$

- ¿Y si la heterogeneidad verdadera es así?

$$\tau(x) = \begin{cases} 9 & \text{edad} < 30, \text{ ingreso} < 20 \\ 2 & \text{edad} < 30, \text{ ingreso} \geq 20 \\ -1 & \text{edad} \geq 30 \end{cases}$$

¿Y con muchas X?

Habría que adivinar la forma

- ▶ Habría que saber de antemano **qué interacciones, qué umbrales, qué no linealidades**.
- ▶ Y si probamos muchas especificaciones, ¿cuántas “salen” significativas por azar?

¿Cuántas salen por azar?

Falsos positivos

- ▶ Cada prueba al 5 %, y ninguna interacción existe de verdad.
- ▶ Si las pruebas son independientes, con k pruebas:


$$P(\text{al menos un falso positivo}) = 1 - (1 - 0,05)^k$$

k	1	5	10	20	50
$P(\text{al menos uno})$	5 %	23 %	40 %	64 %	92 %

- ▶ Con 20 covariables interactuadas ya son 20 pruebas.

¿Y con muchas X?

$\tau(x)$ en el espacio de las Xs



Agenda

- 1 Motivación
- 2 Efectos heterogéneos: ¿para quién funciona?
- 3 ¿Cómo encontrar la heterogeneidad?

De un árbol de regresión a un árbol causal

- Árbol de regresión: aproxima

$$m(x) = E[Y \mid X = x]$$

con hojas útiles para *predecir* Y .

De un árbol de regresión a un árbol causal

- ▶ Árbol de regresión: aproxima

$$m(x) = E[Y \mid X = x]$$

con hojas útiles para *predecir* Y .


- ▶ Árbol causal: aproxima

$$\tau(x) = E[Y(1) - Y(0) \mid X = x]$$

con hojas útiles para *distinguir efectos*.

De un árbol de regresión a un árbol causal

$\tau(x)$ como árbol



El efecto en cada hoja

- Dentro de la hoja L :

$$\hat{\tau}_L = \bar{Y}_{1,L} - \bar{Y}_{0,L}$$

Hoja	n_L	$\bar{Y}_{1,L}$	$\bar{Y}_{0,L}$	$\hat{\tau}_L$
Jóvenes, ingreso bajo	200	68	59	
Jóvenes, ingreso alto	100	66	64	
Mayores	200	62	63	

Problema: no hay y para entrenar

- Predecir Y : vemos Y_i , podemos calcular el error

$$\sum_i (Y_i - \hat{m}(X_i))^2$$

Problema: no hay y para entrenar

- Predecir Y : vemos Y_i , podemos calcular el error

$$\sum_i (Y_i - \hat{m}(X_i))^2$$

- Predecir τ : no vemos τ_i , no podemos calcular

$$\sum_i (\tau_i - \hat{\tau}(X_i))^2$$

- El problema fundamental otra vez: el criterio de CART no se puede evaluar.
- Hay que cambiar el criterio, no sólo lo que se pone en la hoja.

¿Qué pérdida queríamos minimizar?

- Para una partición Π , el árbol predice un efecto constante dentro de cada hoja:

$$\hat{\tau}(x; \Pi) = \hat{\tau}_{\ell(x; \Pi)}.$$

- Idealmente elegiríamos Π minimizando el error de predicción del efecto causal:

$$MSE_{\tau}(\Pi) = E \left[(\tau_i - \hat{\tau}(X_i; \Pi))^2 \right].$$

- Pero aparece otra vez el problema fundamental: τ_i nunca se observa.
- Necesitamos una función de pérdida que podamos calcular sin observar los efectos individuales.

La pérdida honesta

- ▶ Supongamos que usamos:
 - ▶ S^{tr} para construir el árbol;
 - ▶ S^{est} , independiente, para estimar los efectos de las hojas.
- ▶ Athey e Imbens muestran que podemos estimar el error esperado con:

$$\widehat{EMSE}_\tau(\Pi) = -\frac{1}{N^{tr}} \sum_{i \in S^{tr}} \hat{\tau}^2(X_i; \Pi) + \left(\frac{1}{N^{tr}} + \frac{1}{N^{est}} \right) \sum_{\ell \in \Pi} \left[\frac{S_{1,\ell}^2}{p} + \frac{S_{0,\ell}^2}{1-p} \right].$$

- ▶ $S_{1,\ell}^2$: varianza de Y entre tratados en la hoja ℓ .
- ▶ $S_{0,\ell}^2$: varianza de Y entre controles.
- ▶ p : probabilidad de tratamiento.
- ▶ El árbol elige la partición que minimiza esta pérdida.

Entonces, ¿cómo decide si hacer un corte?

El problema del árbol adaptativo

En el árbol adaptativo usamos los mismos datos para dos cosas:

- 1 buscar el corte que produce la mayor diferencia entre efectos;
- 2 estimar los efectos en las hojas que acabamos de encontrar.

Los mismos datos buscan el patrón y después lo miden.

Aunque no haya heterogeneidad, algún corte va a ganar

Supongamos que el efecto es realmente el mismo para todos:

$$\tau_L - \tau_R = 0.$$

Pero para cada corte candidato observamos

Por ejemplo:

corte	1	2	3	4	5
$\hat{\tau}_L - \hat{\tau}_R$	0.8	-1.1	2.0	-3.6	1.4

Aunque no haya heterogeneidad, algún corte va a ganar

Para cada corte k podemos escribir

$$\hat{\Delta}_k = \Delta_k + \varepsilon_k, \quad \Delta_k = \tau_{L,k} - \tau_{R,k}.$$

Si no hay heterogeneidad,

$$\Delta_k = 0 \quad \implies \quad \hat{\Delta}_k = \varepsilon_k.$$

El árbol adaptativo escoge

$$k^* = \arg \max_k |\hat{\Delta}_k| = \arg \max_k |\varepsilon_k|.$$

¿Qué pasa si lo medimos con los mismos datos?

Supongamos que el corte ganador produjo

$$\hat{\tau}_L - \hat{\tau}_R = -3.6.$$


Lo escogimos precisamente porque esa diferencia era grande.

Si ahora usamos los mismos datos para estimar el efecto,

$$\text{diferencia reportada} = -3.6.$$

La idea de la estimación honesta

La solución es separar las dos tareas.



Pros y Cons

► **Ganamos:**

- El ruido que hizo ganar un corte no se reutiliza para medir su efecto.
- Si la diferencia apareció sólo por suerte, tenderá a desaparecer en la muestra nueva.

► **Perdemos:**

- Cada tarea usa menos observaciones.
 - Tenemos menos datos para encontrar los cortes y menos datos para estimar los efectos de las hojas.
- Menos sobreajuste, a cambio de estimaciones más ruidosas.

Review

- ▶ Queremos aprender heterogeneidad en efectos:

$$\tau(x) = E[Y(1) - Y(0) \mid X = x].$$

- ▶ Un árbol causal aproxima $\tau(x)$ con un efecto por hoja:

$$\hat{\tau}_L = \bar{Y}_{1,L} - \bar{Y}_{0,L}.$$

- ▶ Para construir el árbol buscamos cortes donde los efectos a ambos lados sean distintos.
- ▶ Pero probar muchos cortes genera sobreajuste, por eso usamos estimación honesta:
 - ▶ una muestra busca los cortes;
 - ▶ otra muestra estima los efectos en las hojas.
- ▶ Ganamos menos sobreajuste, pero perdemos precisión porque cada tarea usa menos datos.

Next

- ▶ Un árbol causal es inestable, igual que un árbol de regresión.
- ▶ Con árboles de regresión la respuesta fue construir muchos.
- ▶ ¿Qué pasa si construimos muchos árboles causales?