

Bosques causales

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

- 1 Motivación y Recap
- 2 ¿Qué pasa si construimos muchos?
- 3 ¿Cómo estima el bosque el efecto para una observación?
- 4 ¿Y si la probabilidad de tratamiento depende de X ?
- 5 ¿Cuánto le creemos a $\hat{\tau}_j$?
- 6 ¿Qué hacemos con los CATE?

Motivación y Recap

CATE

- Dejamos que el efecto dependa de características observables X :

$$\tau(x) = E[Y(1) - Y(0) \mid X = x] = E[\tau_i \mid X_i = x]$$


- **Conditional** Average Treatment Effect.

- ¿Cómo se relaciona con el ATE?

$$ATE = E[\tau_i] = E_X[E[\tau_i \mid X]] = E_X[\tau(X)]$$

Motivación y Recap

$\tau(x)$ en el espacio de las X s



<https://ignaciomsarmiento.github.io/ArbolHonesto>

Motivación y Recap

Dos problemas

- ▶ Un árbol causal es inestable: otra muestra, otro árbol.
- ▶ La honestidad arregla la estimación, pero cuesta datos:
 - ▶ una mitad corta,
 - ▶ la otra mitad estima.

Motivación y Recap

Dos problemas

- ▶ Un árbol causal es inestable: otra muestra, otro árbol.
- ▶ La honestidad arregla la estimación, pero cuesta datos:
 - ▶ una mitad corta,
 - ▶ la otra mitad estima.
- ▶ Con árboles de regresión la respuesta fue construir muchos.
- ▶ ¿Qué pasa si construimos muchos árboles causales?

Agenda

- 1 Motivación y Recap
- 2 ¿Qué pasa si construimos muchos?**
- 3 ¿Cómo estima el bosque el efecto para una observación?
- 4 ¿Y si la probabilidad de tratamiento depende de X ?
- 5 ¿Cuánto le creemos a $\hat{\tau}_j$?
- 6 ¿Qué hacemos con los CATE?

De un árbol a un bosque

- Lo mismo que con árboles de regresión (bagging, bosques aleatorios):

$$\hat{\tau}(x) = \frac{1}{B} \sum_{b=1}^B \hat{\tau}_b(x) \quad (1)$$

- Cada árbol b :

- 1 toma una submuestra (sin reemplazo),
- 2 la parte en dos: una mitad elige los cortes, la otra estima $\hat{\tau}_L$ en las hojas,
- 3 en cada nodo aleatoriza m de las k variables.


De un árbol a un bosque

¿Y la honestidad?

- ▶ En un árbol, cada observación hace una sola cosa: corta o estima.
- ▶ En el bosque, cada observación corta en algunos árboles y estima en otros.
- ▶ Entre todos los árboles, todos los datos sirven para las dos cosas.

De un árbol a un bosque

$\hat{\tau}(x)$ en el espacio de las X



► Líneas punteadas: el $\tau(x)$ verdadero.

Agenda

- 1 Motivación y Recap
- 2 ¿Qué pasa si construimos muchos?
- 3 ¿Cómo estima el bosque el efecto para una observación?
- 4 ¿Y si la probabilidad de tratamiento depende de X ?
- 5 ¿Cuánto le creemos a $\hat{\tau}_j$?
- 6 ¿Qué hacemos con los CATE?

¿De dónde sale $\hat{\tau}_j$?

- ▶ Tomemos una observación j , con características X_j .
- ▶ En un solo árbol, ¿qué observaciones usamos para estimar el efecto para j ?

¿De dónde sale $\hat{\tau}_j$?

- ▶ Tomemos una observación j , con características X_j .
- ▶ En un solo árbol, ¿qué observaciones usamos para estimar el efecto para j ?
- ▶ Las observaciones que caen en la misma hoja que j .
- ▶ En un árbol, la hoja de j define sus *comparables*.

De una hoja a muchos vecinos

- En árboles distintos, j comparte hoja con observaciones distintas.

Árbol	Observaciones que comparten hoja con j
1	$\{2, 8, 17, 25\}$
2	$\{2, 8, 14, 31, 40\}$
3	$\{2, 17, 25, 40\}$

De una hoja a muchos vecinos

- ▶ En árboles distintos, j comparte hoja con observaciones distintas.

Árbol	Observaciones que comparten hoja con j
1	$\{2, 8, 17, 25\}$
2	$\{2, 8, 14, 31, 40\}$
3	$\{2, 17, 25, 40\}$

- ▶ Algunas observaciones aparecen muchas veces con j .
 - ▶ Otras aparecen pocas veces.
 - ▶ Otras casi nunca.
-
- ▶ α_{ij} : peso que recibe la observación i para aprender sobre el efecto de j .

El bosque aprende una vecindad

► Un árbol dice:

vecino de j o no vecino de j .

El bosque aprende una vecindad

- Un árbol dice:

vecino de j o no vecino de j .


- El bosque dice:

muy vecino algo vecino casi nada vecino.

- Los pesos α_{ij} construyen una noción *suave* de cercanía.

El bosque aprende una vecindad

Dos observaciones distintas



- La cruz: observación objetivo j .
- Tamaño del punto i : peso α_{ij} .
- ¿Por qué la vecindad de la observación mayor es más grande?

Agenda

- 1 Motivación y Recap
- 2 ¿Qué pasa si construimos muchos?
- 3 ¿Cómo estima el bosque el efecto para una observación?
- 4 ¿Y si la probabilidad de tratamiento depende de X ?
- 5 ¿Cuánto le creemos a $\hat{\tau}_j$?
- 6 ¿Qué hacemos con los CATE?

Aleatorización condicional en X

- ▶ Hasta ahora pensamos en un experimento simple:

$$P(T_i = 1) = 0.5.$$

- ▶ Pero un experimento puede asignar tratamiento con probabilidades distintas según las características X_i .

Aleatorización condicional en X

- ▶ Hasta ahora pensamos en un experimento simple:

$$P(T_i = 1) = 0.5.$$

- ▶ Pero un experimento puede asignar tratamiento con probabilidades distintas según las características X_i .
- ▶ Lo importante es que, condicional en X_i , el tratamiento siga siendo aleatorio:

$$(Y_i(1), Y_i(0)) \perp T_i \mid X_i.$$

- ▶ Definimos la probabilidad de tratamiento:

$$e(X_i) = P(T_i = 1 \mid X_i).$$

- ▶ En un experimento, $e(X_i)$ es conocido por diseño.

Ortogonalizar

- Queremos quitar de T_i la parte que viene dada por el diseño:

$$T_i - e(X_i).$$

- nos quedamos con la parte de T_i que no era predecible por X_i .
- También podemos quitar de Y_i la parte predecible a partir de X_i :

$$Y_i - m(X_i),$$

donde

$$m(X_i) = E[Y_i \mid X_i].$$

Ortogonalizar

- Queremos quitar de T_i la parte que viene dada por el diseño:

$$T_i - e(X_i).$$

- nos quedamos con la parte de T_i que no era predecible por X_i .
- También podemos quitar de Y_i la parte predecible a partir de X_i :

$$Y_i - m(X_i),$$

donde

$$m(X_i) = E[Y_i \mid X_i].$$

- Entonces trabajamos con:

$$\tilde{T}_i = T_i - e(X_i), \quad \tilde{Y}_i = Y_i - \hat{m}(X_i).$$

Ortogonalizar

Residuos contra residuos

- Para estimar el efecto de la observación j , usamos los pesos α_{ij} aprendidos por el bosque.

$$\hat{\tau}_j = \frac{\sum_i \alpha_{ij} (T_i - e(X_i)) (Y_i - \hat{m}(X_i))}{\sum_i \alpha_{ij} (T_i - e(X_i))^2}.$$

- Es una regresión local de residuos sobre residuos.
- Los pesos α_{ij} dicen qué observaciones son relevantes para aprender sobre j .

Ortogonalizar

Residuos contra residuos

- Para estimar el efecto de la observación j , usamos los pesos α_{ij} aprendidos por el bosque.

$$\hat{\tau}_j = \frac{\sum_i \alpha_{ij} (T_i - e(X_i)) (Y_i - \hat{m}(X_i))}{\sum_i \alpha_{ij} (T_i - e(X_i))^2}.$$

- Es una regresión local de residuos sobre residuos.
- Los pesos α_{ij} dicen qué observaciones son relevantes para aprender sobre j .
- Si el experimento es 50/50:

$$e(X_i) = 0.5.$$

Agenda

- 1 Motivación y Recap
- 2 ¿Qué pasa si construimos muchos?
- 3 ¿Cómo estima el bosque el efecto para una observación?
- 4 ¿Y si la probabilidad de tratamiento depende de X ?
- 5 ¿Cuánto le creemos a $\hat{\tau}_j$?
- 6 ¿Qué hacemos con los CATE?

Incertidumbre sobre el CATE

- Para cada observación j , el bosque produce una estimación

$$\hat{\tau}_j = \hat{\tau}(X_j).$$

- Pero otra muestra habría producido otro bosque y otro $\hat{\tau}_j$.

Incertidumbre sobre el CATE

- Para cada observación j , el bosque produce una estimación

$$\hat{\tau}_j = \hat{\tau}(X_j).$$


- Pero otra muestra habría producido otro bosque y otro $\hat{\tau}_j$.
- Wager y Athey (2018): con árboles honestos, submuestreo y condiciones de regularidad,

$$\hat{\tau}_j \approx N(\tau(X_j), \text{Var}(\hat{\tau}_j)) .$$

- Entonces podemos construir intervalos:

$$\hat{\tau}_j \pm 1.96 \hat{\text{se}}(\hat{\tau}_j).$$

Intervalos para $\tau(x)$



► Punteada: $\tau(x)$ verdadero.

¿Por qué importa la honestidad?

- ▶ Sin honestidad, los mismos datos:

- 1 buscan dónde parece haber una diferencia grande;
- 2 estiman esa misma diferencia.

¿Por qué importa la honestidad?

- ▶ Sin honestidad, los mismos datos:
 - 1 buscan dónde parece haber una diferencia grande;
 - 2 estiman esa misma diferencia.
- ▶ El corte “ganador” puede haber ganado simplemente por ruido.
- ▶ Con honestidad:
 - ▶ unos datos buscan
 - ▶ otros estiman
- ▶ Esto permite hacer inferencia después de haber buscado heterogeneidad.

Agenda

- 1 Motivación y Recap
- 2 ¿Qué pasa si construimos muchos?
- 3 ¿Cómo estima el bosque el efecto para una observación?
- 4 ¿Y si la probabilidad de tratamiento depende de X ?
- 5 ¿Cuánto le creemos a $\hat{\tau}_j$?
- 6 ¿Qué hacemos con los CATE?

¿Qué hacemos con los CATE?

- ▶ Evaluar si las diferencias en los CATE estimados reflejan heterogeneidad real o solamente ruido. Ej:
 - ▶ El bosque estima $\hat{\tau}(X_j) = 8$ para algunos usuarios y $\hat{\tau}(X_k) = -1$ para otros.
 - ▶ ¿Esas diferencias aparecen de verdad en el experimento, o son sólo error de estimación?

¿Qué hacemos con los CATE?

- ▶ Evaluar si las diferencias en los CATE estimados reflejan heterogeneidad real o solamente ruido. Ej:
 - ▶ El bosque estima $\hat{\tau}(X_j) = 8$ para algunos usuarios y $\hat{\tau}(X_k) = -1$ para otros.
 - ▶ ¿Esas diferencias aparecen de verdad en el experimento, o son sólo error de estimación?
- ▶ Entender qué características X están asociadas con diferencias en la respuesta al tratamiento. Ej:
 - ▶ ¿el descuento funciona mejor entre usuarios jóvenes?
 - ▶ ¿Entre usuarios de ingreso bajo?

¿Qué hacemos con los CATE?

- ▶ Usar los CATE para focalizar el tratamiento cuando no podemos tratar a todos. Ej:
 - ▶ Si sólo podemos dar el descuento al 30%, elegimos las observaciones con mayor $\hat{\tau}(X_j)$.
 - ▶ Luego preguntamos si el efecto promedio del tratamiento en ese grupo es mayor que el ATE.

¿Qué hacemos con los CATE?

- ▶ Usar los CATE para focalizar el tratamiento cuando no podemos tratar a todos. Ej:
 - ▶ Si sólo podemos dar el descuento al 30%, elegimos las observaciones con mayor $\hat{\tau}(X_j)$.
 - ▶ Luego preguntamos si el efecto promedio del tratamiento en ese grupo es mayor que el ATE.
- ▶ Evaluar la focalización con datos distintos de los usados para construirla. Ej:
 - ▶ Una muestra construye el ranking y otra muestra comprueba si los priorizados realmente responden más.

Next

- ▶ Lunes (festivo): árboles causales “a mano”, con un agente.
- ▶ Miércoles (en CLASE): bosques causales sobre los mismos datos.