Texto como datos: modelos de tópicos

Ciencia de Datos y Econometría Aplicada

Ignacio Sarmiento-Barbieri

Universidad de los Andes

Agenda

1. ¿De qué hablan los documentos?
2. La máquina que escribe documentos
3. Ingeniería reversa
4. Elegir los hiperparámetros
5. Aplicación

Modelos de tópicos

Intro

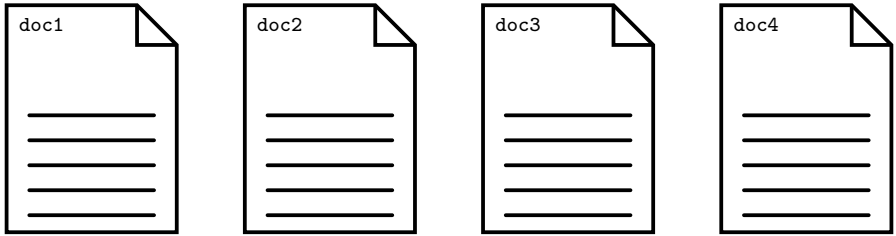
- El problema del texto suele ser la dimensionalidad
- La DTM suele ser muy grande y poco densa
- Buscamos de cierta forma resumirla: pocas variables que digan de qué habla cada documento.
- Es reducción de dimensionalidad no supervisada: no hay y.

Modelos de tópicos

Un poco de historia

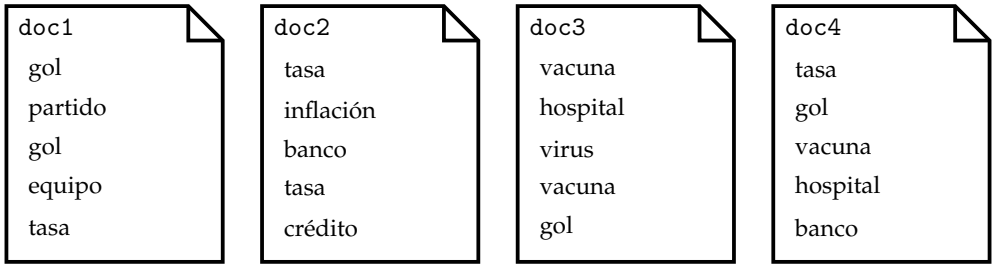
- Antes de los 2000: factorizar la DTM con álgebra lineal (PCA/SVD). Se llamaba *análisis semántico latente*.
- Blei, Ng y Jordan (2003) propusieron tomarse en serio la bolsa de palabras y modelar cómo se generan la frecuensia de palabras.
- Ese modelo es la **Asignación Latente de Dirichlet** (LDA).
- LDA es un modelo probabilístico, cuenta una historia de cómo se escribe cada documento.

El problema



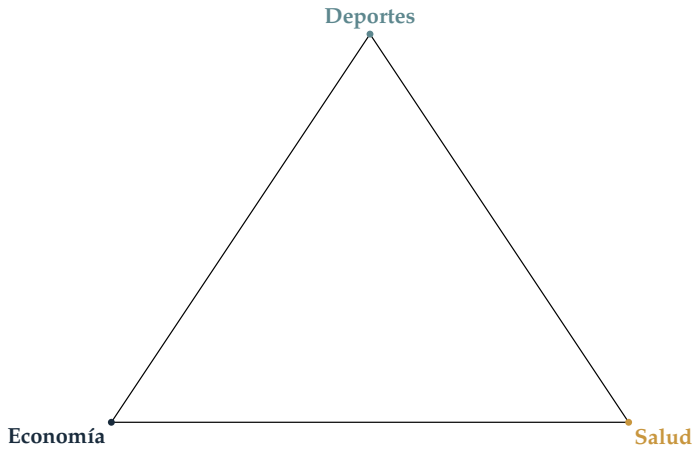
- ¿De qué hablan?

El problema

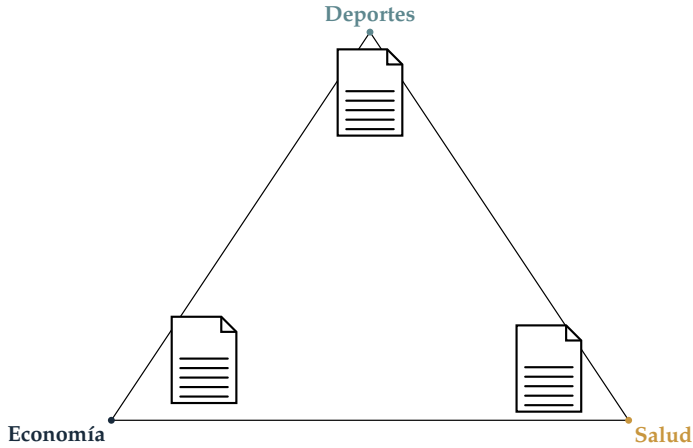


- Vemos palabras y queremos los temas detrás de las palabras.

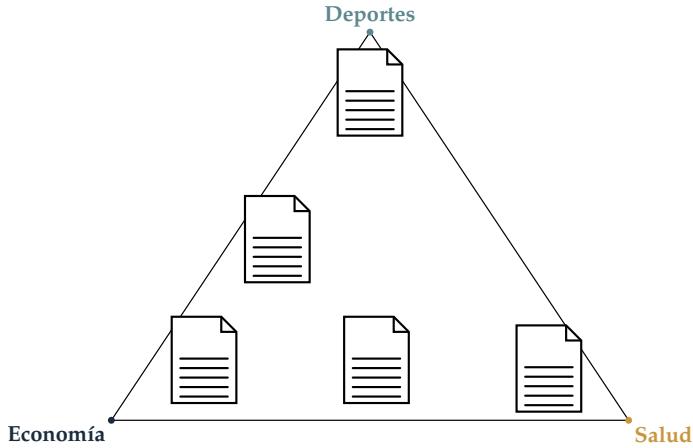
Documentos como mezclas de tópicos (temas)



Documentos como mezclas de tópicos (temas)



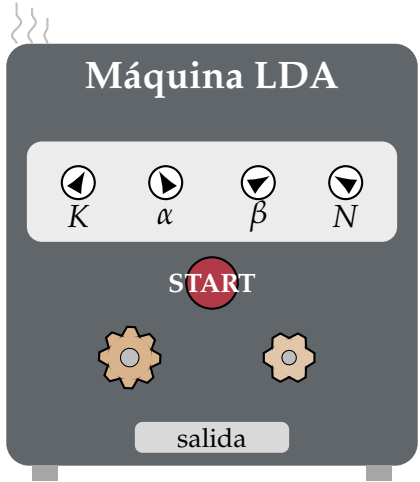
Documentos como mezclas de tópicos (temas)



Agenda

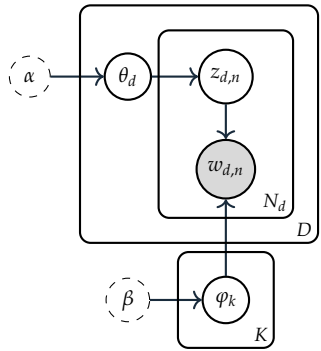
1. ¿De qué hablan los documentos?
2. La máquina que escribe documentos
3. Ingeniería reversa
4. Elegir los hiperparámetros
5. Aplicación

La máquina LDA



- cede.uniandes.edu.co/DSEA/LDA.html

El modelo probabilistico



El modelo probabilistico

$$p(\mathbf{w}, \mathbf{z}, \theta, \varphi \mid \alpha, \beta)$$

El modelo probabilistico

$$p(\mathbf{w}, \mathbf{z}, \theta, \varphi \mid \alpha, \beta) = \prod_{k=1}^{K} p(\varphi_k \mid \beta)$$

El modelo probabilistico

$$p(\mathbf{w}, \mathbf{z}, \theta, \varphi \mid \alpha, \beta) = \prod_{k=1}^{K} p(\varphi_k \mid \beta) \prod_{d=1}^{D} \Big[p(\theta_d \mid \alpha)$$

El modelo probabilistico

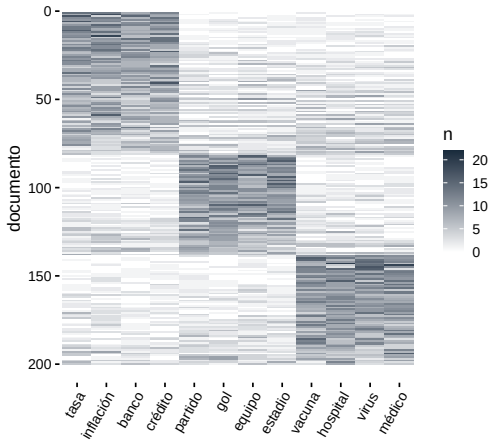
$$p(\mathbf{w}, \mathbf{z}, \theta, \varphi \mid \alpha, \beta) = \prod_{k=1}^{K} p(\varphi_k \mid \beta) \prod_{d=1}^{D} \Big[p(\theta_d \mid \alpha) \prod_{n=1}^{N_d} p(z_{d,n} \mid \theta_d)$$

El modelo probabilistico

$$p(\mathbf{w}, \mathbf{z}, \theta, \varphi \mid \alpha, \beta) = \prod_{k=1}^{K} p(\varphi_k \mid \beta) \prod_{d=1}^{D} \left[p(\theta_d \mid \alpha) \prod_{n=1}^{N_d} p(z_{d,n} \mid \theta_d)\, p(w_{d,n} \mid \varphi_{z_{d,n}}) \right]$$

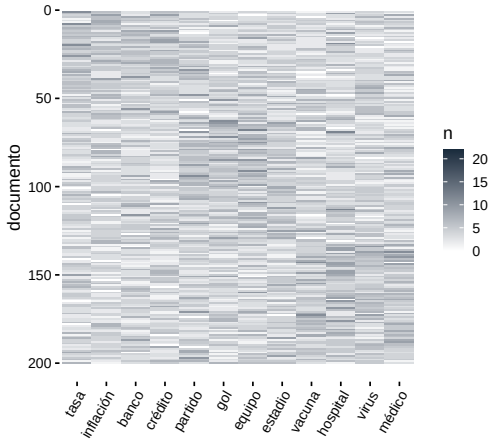
Lo que deja la máquina: la DTM

Ej: 200 documentos ($N = 50$, $V = 12$), con $\alpha = 0{,}3$



Observamos la DTM

Ej: 200 documentos ($N = 50$, $V = 12$), con $\alpha = 10$



Agenda

1. ¿De qué hablan los documentos?
2. La máquina que escribe documentos
3. Ingeniería reversa
4. Elegir los hiperparámetros
5. Aplicación

Ingeniería reversa

¿Qué queremos recuperar?

- Observamos la DTM.

Ingeniería reversa

¿Qué queremos recuperar?

- Observamos la DTM.
- No observamos
  - la distribución de palabras de cada tópico (φ),
  - la distribución de tópicos de cada documento (θ),
  - el tópico asignado a cada palabra (z).

Ingeniería reversa

¿Qué queremos recuperar?

- Observamos la DTM.
- No observamos
  - la distribución de palabras de cada tópico (φ),
  - la distribución de tópicos de cada documento (θ),
  - el tópico asignado a cada palabra (z).
- Ingeniería reversa: recuperar esas estructuras ocultas a partir de las palabras observadas.

Ingeniería reversa

Si conociéramos las asignaciones, bastaría con contar

médico vacuna vacuna vacuna vacuna gol hospital virus estadio partido vacuna
virus equipo hospital equipo

Ingeniería reversa

Si conociéramos las asignaciones, bastaría con contar

médico vacuna vacuna vacuna vacuna gol hospital virus estadio partido vacuna virus equipo hospital equipo

- **La distribución de tópicos**: contar cuántas palabras están asignadas a cada tópico. Economía 0, Deportes 3, Salud 12, de 15 palabras.

Ingeniería reversa

Si conociéramos las asignaciones, bastaría con contar

médico vacuna vacuna vacuna vacuna gol hospital virus estadio partido vacuna virus equipo hospital equipo

- **La distribución de tópicos**: contar cuántas palabras están asignadas a cada tópico. Economía 0, Deportes 3, Salud 12, de 15 palabras.
- **Las distribuciones de palabras**: entre todas las palabras asignadas a Deportes en el corpus, ¿qué fracción es *gol*?

Ingeniería reversa

Si conociéramos las asignaciones, bastaría con contar

médico vacuna vacuna vacuna vacuna gol hospital virus estadio partido vacuna virus equipo hospital equipo

- **La distribución de tópicos**: contar cuántas palabras están asignadas a cada tópico. Economía 0, Deportes 3, Salud 12, de 15 palabras.
- **Las distribuciones de palabras**: entre todas las palabras asignadas a Deportes en el corpus, ¿qué fracción es *gol*?

$$\hat{\theta}_{d,k} = \frac{\#\{n : z_{d,n} = k\}}{N_d} \qquad \hat{\varphi}_{k,w} = \frac{\#\{\text{veces que } w \text{ está asignada a } k\}}{\#\{\text{palabras asignadas a } k\}}$$

Ingeniería reversa

Si conociéramos las distribuciones, podríamos inferir las asignaciones

$$\underbrace{p(z_{d,n} = k \mid w_{d,n} = w,\ \theta_d,\ \varphi)}_{\text{posterior}} \propto \underbrace{p(w_{d,n} = w \mid z_{d,n} = k,\ \varphi)}_{\substack{\varphi_{k,w} \\ \text{verosimilitud}}} \underbrace{p(z_{d,n} = k \mid \theta_d)}_{\substack{\theta_{d,k} \\ \text{prior}}}$$

Ingeniería reversa

Si conociéramos las distribuciones, podríamos inferir las asignaciones

$$\underbrace{p(z_{d,n} = k \mid w_{d,n} = w,\ \theta_d,\ \varphi)}_{\text{posterior}} \propto \underbrace{p(w_{d,n} = w \mid z_{d,n} = k,\ \varphi)}_{\substack{\varphi_{k,w} \\ \text{verosimilitud}}} \underbrace{p(z_{d,n} = k \mid \theta_d)}_{\substack{\theta_{d,k} \\ \text{prior}}}$$

- Bayes junta dos pistas: cuánto pesa el tópico en el documento ($\theta_{d,k}$) y cuánto usa el tópico esa palabra ($\varphi_{k,w}$).

Ingeniería reversa

Si conociéramos las distribuciones, podríamos inferir las asignaciones

$$\underbrace{p(z_{d,n} = k \mid w_{d,n} = w,\ \theta_d,\ \varphi)}_{\text{posterior}} \propto \underbrace{p(w_{d,n} = w \mid z_{d,n} = k,\ \varphi)}_{\substack{\varphi_{k,w} \\ \text{verosimilitud}}} \underbrace{p(z_{d,n} = k \mid \theta_d)}_{\substack{\theta_{d,k} \\ \text{prior}}}$$

- Bayes junta dos pistas: cuánto pesa el tópico en el documento ($\theta_{d,k}$) y cuánto usa el tópico esa palabra ($\varphi_{k,w}$).

gol en A: $\theta_A = (0{,}9;\ 0{,}05;\ 0{,}05)$



Eco 0,53 Dep 0,44

gol en B: $\theta_B = (0{,}1;\ 0{,}8;\ 0{,}1)$



Dep 0,98

Ingeniería reversa

Si conociéramos las distribuciones, podríamos inferir las asignaciones

$$\underbrace{p(z_{d,n} = k \mid w_{d,n} = w,\ \theta_d,\ \varphi)}_{\text{posterior}} \propto \underbrace{p(w_{d,n} = w \mid z_{d,n} = k,\ \varphi)}_{\substack{\varphi_{k,w} \\ \text{verosimilitud}}} \underbrace{p(z_{d,n} = k \mid \theta_d)}_{\substack{\theta_{d,k} \\ \text{prior}}}$$

- Bayes junta dos pistas: cuánto pesa el tópico en el documento ($\theta_{d,k}$) y cuánto usa el tópico esa palabra ($\varphi_{k,w}$).
- Todo el contexto que usa LDA es θ_d: el orden y las palabras vecinas no entran.

gol en A: $\theta_A = (0{,}9;\ 0{,}05;\ 0{,}05)$



Eco 0,53 Dep 0,44

gol en B: $\theta_B = (0{,}1;\ 0{,}8;\ 0{,}1)$



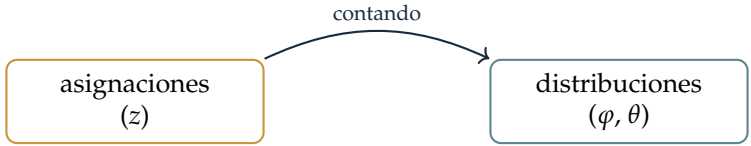
Dep 0,98

El huevo y la gallina

asignaciones
(z)

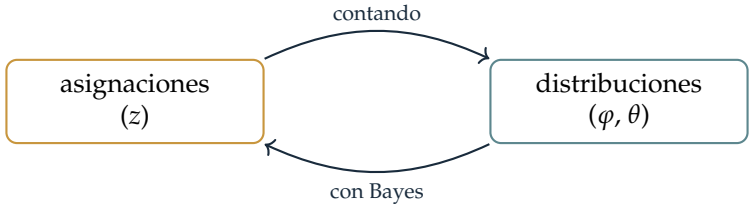
distribuciones
(φ, θ)

El huevo y la gallina



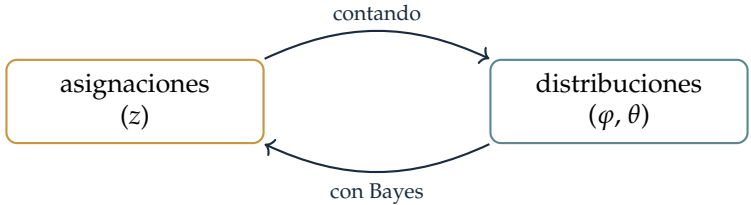
- Si conozco las asignaciones, puedo estimar las distribuciones (contar).

El huevo y la gallina



- Si conozco las asignaciones, puedo estimar las distribuciones (contar).
- Si conozco las distribuciones, puedo calcular probabilidades de asignación (Bayes).

El huevo y la gallina



- Si conozco las asignaciones, puedo estimar las distribuciones (contar).
- Si conozco las distribuciones, puedo calcular probabilidades de asignación (Bayes).
- Pero no conozco ninguna de las dos: hace falta un algoritmo iterativo.

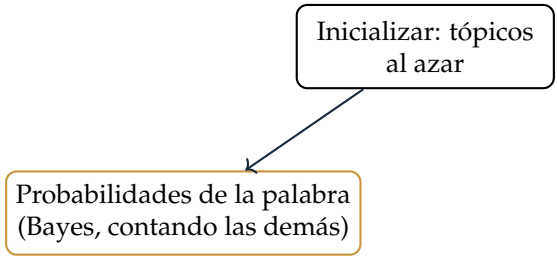
¿Cómo lo resuelve Gibbs?

Muestreo de Gibbs: probabilidades por Bayes $\rightarrow$ muestrear el tópico de cada palabra $\rightarrow$ repetir

Inicializar: tópicos al azar

¿Cómo lo resuelve Gibbs?

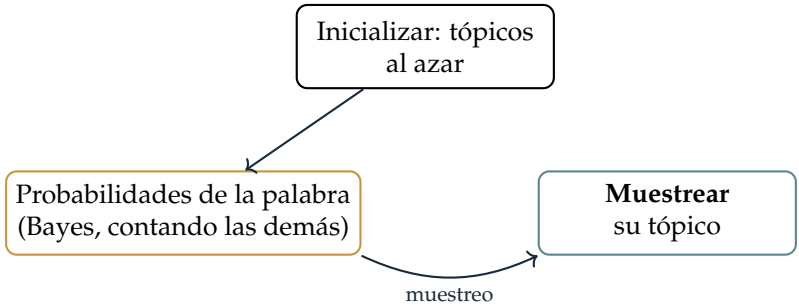
Muestreo de Gibbs: probabilidades por Bayes → muestrear el tópico de cada palabra → repetir



- Para cada palabra: probabilidades por Bayes, contando las asignaciones de las demás palabras.

¿Cómo lo resuelve Gibbs?

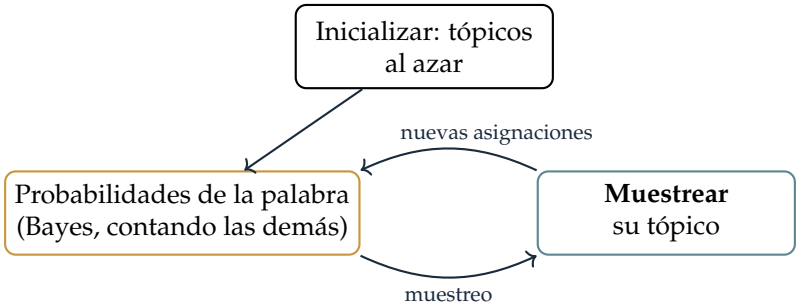
Muestreo de Gibbs: probabilidades por Bayes → muestrear el tópico de cada palabra → repetir



- Para cada palabra: probabilidades por Bayes, contando las asignaciones de las demás palabras.
- Se muestrea su tópico con esas probabilidades — no se elige el más probable.

¿Cómo lo resuelve Gibbs?

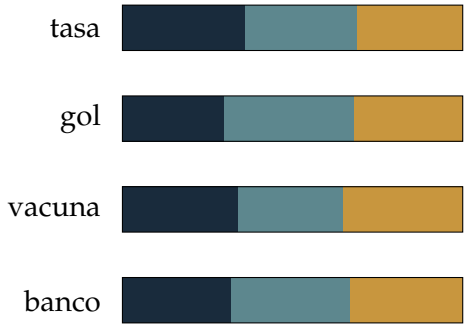
Muestreo de Gibbs: probabilidades por Bayes → muestrear el tópico de cada palabra → repetir



- Para cada palabra: probabilidades por Bayes, contando las asignaciones de las demás palabras.
- Se muestrea su tópico con esas probabilidades — no se elige el más probable.
- Muchas vueltas: las asignaciones muestreadas se estabilizan y $\hat{\theta}$, $\hat{\varphi}$ salen contando.

Las asignaciones se refinan

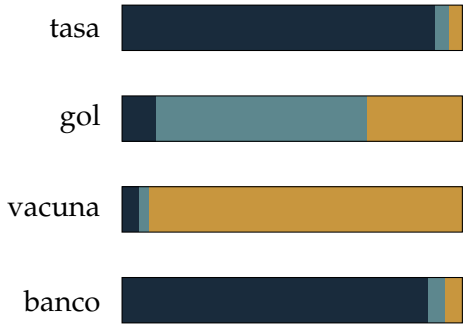
Cuánto de cada palabra se le asigna a Economía, Deportes y Salud



- Al principio, los muestreos son casi al azar.
- `cede.uniandes.edu.co/DSEA/LDA.html`

Las asignaciones se refinan

Cuánto de cada palabra se le asigna a Economía, Deportes y Salud



- Con las vueltas, los muestreos se concentran.
- `cede.uniandes.edu.co/DSEA/LDA.html`

¿Por qué necesitamos aproximar?

$$p(\mathbf{w} \mid \alpha, \beta) = \int\int \sum_{\mathbf{z}} p(\mathbf{w}, \mathbf{z}, \theta, \varphi \mid \alpha, \beta)\, d\theta\, d\varphi$$

¿Por qué necesitamos aproximar?

$$p(\mathbf{w} \mid \alpha, \beta) = \int\int \sum_{\mathbf{z}} p(\mathbf{w}, \mathbf{z}, \theta, \varphi \mid \alpha, \beta)\, d\theta\, d\varphi$$

$$\#\{\mathbf{z}\} = K^{D \cdot N} = 3^{200 \times 50} = 3^{10.000}$$

Significado de los tópicos

- El modelo encuentra tres tópicos, pero no sabe cómo se llaman.

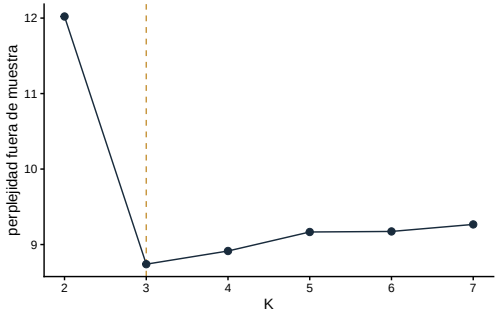
Significado de los tópicos

- El modelo encuentra tres tópicos, pero no sabe cómo se llaman.
- El nombre lo ponemos nosotros, mirando las palabras de cada tópico.

Agenda

1. ¿De qué hablan los documentos?
2. La máquina que escribe documentos
3. Ingeniería reversa
4. Elegir los hiperparámetros
5. Aplicación

¿Cómo elegimos los hiperparámetros?



- Validación cruzada. La medida de performance esta dado por perplejidad

$$\text{Perplejidad} = \exp\left(-\frac{\log p(\mathbf{w}_{\text{test}})}{N_{\text{test}}}\right)$$

Agenda

1. ¿De qué hablan los documentos?
2. La máquina que escribe documentos
3. Ingeniería reversa
4. Elegir los hiperparámetros
5. Aplicación

Transparencia en el FOMC

TRANSPARENCY AND DELIBERATION WITHIN THE FOMC: A COMPUTATIONAL LINGUISTICS APPROACH*

STEPHEN HANSEN
MICHAEL MCMAHON
ANDREA PRAT

How does transparency, a key feature of central bank design, affect monetary policy makers' deliberations? Theory predicts a positive discipline effect and negative conformity effect. We empirically explore these effects using a natural experiment in the Federal Open Market Committee in 1993 and computational linguistics algorithms. We first find large changes in communication patterns after transparency. We then propose a difference-in-differences approach inspired by the career concerns literature, and find evidence for both effects. Finally, we construct an influence measure that suggests the discipline effect dominates. *JEL Codes*: E52, E58, D78.

Transparencia en el FOMC

- **Pregunta**: ¿la transparencia cambia cómo deliberan los banqueros centrales?
- **Datos**: las transcripciones de las reuniones del FOMC.
- **Variación**: en 1993 se supo que las transcripciones se iban a publicar.
- **Medición**: LDA convierte cada intervención en un vector θ de proporciones de tópicos.
- **Diseño**: diferencias en diferencias, antes y después de 1993, entre miembros con más y menos preocupación por su carrera.

Transparencia en el FOMC: el resultado

- La teoría predice dos efectos de la transparencia sobre los miembros con carrera por delante:

Transparencia en el FOMC: el resultado

- La teoría predice dos efectos de la transparencia sobre los miembros con carrera por delante:
- **Disciplina**: llegan mejor preparados — más referencias a datos y números, y cubren más tópicos en la discusión económica.

Transparencia en el FOMC: el resultado

- La teoría predice dos efectos de la transparencia sobre los miembros con carrera por delante:
- **Disciplina**: llegan mejor preparados — más referencias a datos y números, y cubren más tópicos en la discusión económica.
- **Conformidad**: en la discusión de política se alinean más con el consenso — menos disenso.

Transparencia en el FOMC: el resultado

- La teoría predice dos efectos de la transparencia sobre los miembros con carrera por delante:
- **Disciplina**: llegan mejor preparados — más referencias a datos y números, y cubren más tópicos en la discusión económica.
- **Conformidad**: en la discusión de política se alinean más con el consenso — menos disenso.
- El dif-en-dif encuentra los dos; una medida de influencia sugiere que domina la disciplina.

Resumen

- LDA es un modelo probabilistico
- Estimar es el problema del huevo y la gallina;
  - estimamos iterativamento con muestreo de Gibbs (o inferencia variacional)
- LDA usa el contexto del documento (θ_d), no el de la frase.
- Los tópicos no tienen nombre: el nombre lo ponemos nosotros.
- K se elige combinando perplejidad fuera de muestra con coherencia y lectura de los tópicos.

Next

- Miércoles LDA con los resumenes CEPAL.
- Traer instalados: `topicmodels`, `tidytext`.